

跨药物共有失效签名的识别与因果推断

龙高弘

2026 年 7 月 14 日

内容概览

- 1 研究目标
- 2 名词解释
- 3 实现步骤
- 4 SVM 原理
- 5 SFFS 具体解释
- 6 SHAP 原理
- 7 MR 具体解释

- 整合公开组学数据（GEO、PRIDE、SPARC），分别提取三种主流药物（anti-TNF、VEDO、UST）的失效签名。
- 取交集得到 **跨药物共有失效签名**（DTT-IBD 患者共有的基线特征）。
- 利用 UKB-PPP 蛋白组数据进行 **孟德尔随机化（MR）** 因果推断，验证签名与治疗应答的因果关系。

跨药物共有失效签名 DTT-IBD 患者共有的基线临床特征。

anti-TNF / VEDO / UST 三种主流治疗炎症性肠病 (IBD) 的生物制剂。

MR 孟德尔随机化 (Mendelian Randomization), 利用遗传变异作为工具变量推断暴露与结局的因果效应。

SVM 支持向量机 (Support Vector Machine), 一种监督学习分类器。

SFFS 序列浮动前向选择 (Sequential Floating Forward Selection), 用于特征选择的启发式搜索算法。

SHAP SHapley Additive exPlanations, 基于博弈论的特征重要性解释方法。

- ① **SVM + SFFS** 选择对区分药物是否有效具贡献度的特征。
- ② **SHAP** 模型计算各特征对预测的贡献度，找出对失效具有高贡献度特征。
- ③ 依据 DTT-IBD 定义，筛选在两种或三种药物中均具有高贡献度的特征作为候选签名。
- ④ 利用 **MR** 验证候选签名与治疗失效的因果关联。

核心原理

- 在高维特征空间中构造最优分类超平面，使得不同类别样本之间的几何间隔（geometric margin）最大化。
- 对于非线性可分情形，引入核函数（kernel function）将原始特征映射至再生核希尔伯特空间（RKHS），实现隐式高维映射。

在本研究中的角色

- 作为 SFFS 的 **评估器（evaluator）**：对每个候选特征子集训练 SVM 分类器，以交叉验证准确率或 AUC 作为该子集的适应度得分。
- 通过最大化失效组与有效组之间的判别边界，确保入选特征具有最优的类间区分能力。

序列浮动前向选择 (SFFS)

- **目的：** 从高维特征集中选出最优子集，避免穷举搜索，同时克服传统前向选择的“嵌套效应”。
- **基本流程：**
 - ① 初始化空特征集。
 - ② **前向：** 每次添加一个使目标函数（如分类准确率）提升最大的特征。
 - ③ **浮动：** 在添加后，检查是否可以移除某个已选特征以进一步提升性能（条件移除）。
 - ④ 重复直到达到预设特征数或性能不再改善。
- **优点：** 具有回溯能力，能修正早期选择的次优特征，比普通前向选择更灵活。
- **本应用：** 结合 SVM 的分类性能作为目标函数，筛选出与药物失效最相关的特征组合。

SHAP: Shapley 加性解释

理论根基

SHAP (SHapley Additive exPlanations) 将博弈论中的 **Shapley 值** (Shapley value) 引入机器学习可解释性领域。对于给定预测样本, SHAP 值量化各特征对模型输出偏离基准值 (base value) 的边际贡献。

Shapley 值计算公式:

$$\phi_j(f) = \sum_{S \subseteq N \setminus \{j\}} \frac{|S|!(|N| - |S| - 1)!}{|N|!} [f(S \cup \{j\}) - f(S)]$$

其中 N 为全部特征集合, S 为不包含特征 j 的任意子集, $f(S)$ 为基于子集 S 的模型预测期望值。

在本研究中的功能:

- 对 SVM+SFBS 筛选所得特征子集, 计算各特征在区分失效组与应答组时的 SHAP 值, 依据 SHAP 值绝对值的大小排序与正负, 识别对药物失效预测贡献最大的核心生物标志物。

孟德尔随机化 (Mendelian Randomization)

- **基本原理**：利用遗传变异（如 SNP）作为工具变量（IV），模拟随机对照试验，推断暴露（如蛋白水平）与结局（治疗失效）的因果关系。
- **三大假设**：
 - ① **关联性**：IV 与暴露强相关。
 - ② **独立性**：IV 与混杂因素无关。
 - ③ **排他性**：IV 仅通过暴露影响结局。
- **常用方法**：检索符合三大假设的暴露的工具变量，判断工具变量与结局间是否存在关系。
- **本应用**：验证候选签名（蛋白或基因特征）是否具有因果效应，而非仅统计相关，提高标志物的可靠度。