

高校管理岗编制预测：高斯过程回归模型

2026 年 6 月 20 日

1 模型概述

1.1 研究背景与目标

高校管理岗编制预测涉及人事规划，需兼顾职能强度与预算约束。本研究采用多特征组合策略，候选特征涵盖本科生、研究生、在编教师、留学生/长期留学生、公共课相关变量（学分、数量、是否公共课）以及折合学生数。通过系统组合，共构建 16 种特征组合，以 2030 年预测与官方拟合值的 MAE 为排序依据，选取最优组合进行展示。验证策略采用“训练—验证—预测”三步框架：以 2025 年数据（已补齐在编教师）训练模型，2026 年实际数据验证模型精度，经统计检验后外推至 2030 年，以保障外推可信度。

研究目标为预测 2030 年各学院管理岗编制人数（含组织员），并划分为正科、副科、科级以下。核心方法为高斯过程回归（Gaussian Process Regression, GPR），其特点在于：将编制人数视为多维度特征变量的非线性函数；通过核函数刻画学院间的相似性，自动估计预测不确定性；采用多特征组合策略，以 2025 年数据训练、2026 年数据验证，按与官方拟合值的 MAE 排序选取最优组合。

验证策略如下：

训练集（2025 年） $\xrightarrow{\text{GPR 拟合}}$ 验证集（2026 年） $\xrightarrow{\text{假设检验}}$ 2030 年预测

1.2 符号说明

本研究对所用符号进行系统说明，如表 1 所示。

需特别说明以下三点：其一，研究排除了上海国际知识产权学院与中德工程学院，原因在于上述学院数据具有特殊性，易对模型估计产生干扰；其二，所有编制人数均指含组织员的总量，组织员人数单独列示，后续层级拆分需先行扣除；其三，最终非组织员编制按 2:3:5 比例拆分为正科、副科与科级以下，该比例为学校人事处的统一规定。特征向量的维度因组合而异，介于 3 维至 5 维之间。

表 1: 符号说明

符号	含义
i	学院索引, $i = 1, 2, \dots, n$ ($n = 27$, 排除 2 个特殊学院)
t	年份索引, $t = 2025, 2026, 2030$
$\mathbf{x}_i$	第 i 个学院的特征向量 (3–5 维, 视组合而定)
O_i	第 i 个学院的组织员人数
$B_{i,t}$	第 i 个学院第 t 年的实际编制人数 (含组织员)
$\hat{B}_{i,t}$	GPR 预测编制人数 (含组织员)
$\hat{B}_i^{\text{约束}}$	预算约束后含组织员的编制人数
$\hat{B}_i^{\text{非组织员}}$	约束后非组织员编制人数, $\hat{B}_i^{\text{非组织员}} = \hat{B}_i^{\text{约束}} - O_i$
$f(\mathbf{x})$	潜在编制人数函数, 服从高斯过程
$\mu(\mathbf{x}^*)$	GPR 预测均值函数
$\sigma^2(\mathbf{x}^*)$	GPR 预测方差 (不确定性)
$B_i^{\text{预算}}$	预算约束人数 (含组织员)
$\alpha_1, \alpha_2, \alpha_3$	正科、副科、科以下拆分比例 (0.2, 0.3, 0.5)

2 GPR 方法原理

2.1 高斯过程

高斯过程回归的核心思想在于, 不直接预设编制人数与特征之间的具体函数形式 (如线性或二次), 而是假设该函数服从高斯过程。由此, 任意有限个输入点对应的函数值联合服从多元高斯分布:

$$f(\mathbf{x}) \sim \mathcal{GP}(m(\mathbf{x}), k(\mathbf{x}, \mathbf{x}')) \quad (1)$$

均值函数 (此处取零均值或数据均值) 为:

$$m(\mathbf{x}) = \mathbb{E}[f(\mathbf{x})] \quad (2)$$

协方差函数 (核函数) 采用 RBF 核与白噪声核的组合:

$$k(\mathbf{x}, \mathbf{x}') = \sigma^2 \exp\left(-\frac{\|\mathbf{x} - \mathbf{x}'\|^2}{2\ell^2}\right) + \sigma_n^2 \delta(\mathbf{x}, \mathbf{x}') \quad (3)$$

RBF 核的直观含义为, 两学院特征越接近, 其编制人数越相似; 白噪声项则用于捕捉观测误差。GPR 的显著优势在于其天然提供预测区间 $\mu(\mathbf{x}^*) \pm 1.96\sigma(\mathbf{x}^*)$, 该特性对于编制规划具有重要意义——不仅需获取点预测值, 还需量化预测的不确定性。

2.2 最大化边际似然确定超参数

边际似然可理解为：给定超参数时，观察到现有训练数据的概率。通过对潜在函数积分消去后，得到多元高斯分布：

$$p(\mathbf{y} | \mathbf{X}) = \int p(\mathbf{y} | \mathbf{f}) p(\mathbf{f} | \mathbf{X}) d\mathbf{f} = \mathcal{N}(\mathbf{0}, \mathbf{K} + \sigma_n^2 \mathbf{I}_n) \quad (4)$$

直接最大化边际似然存在数值困难——概率值极小，易导致浮点数下溢。因此取对数处理：

$$\log p(\mathbf{y} | \mathbf{X}) = -\frac{1}{2} \mathbf{y}^\top (\mathbf{K} + \sigma_n^2 \mathbf{I}_n)^{-1} \mathbf{y} - \frac{1}{2} \log |\mathbf{K} + \sigma_n^2 \mathbf{I}_n| - \frac{n}{2} \log 2\pi \quad (5)$$

优化器采用 L-BFGS-B，配合 50 次随机重启，以避免陷入局部最优。最终确定的三个超参数分别为信号方差、长度尺度与噪声方差。

2.3 预测函数的推导

将训练输出与待预测点的输出联合构造高斯分布：

$$\begin{bmatrix} \mathbf{y} \\ y^* \end{bmatrix} \sim \mathcal{N}\left(\mathbf{0}, \begin{bmatrix} \mathbf{K} + \sigma_n^2 \mathbf{I}_n & \mathbf{k}_* \\ \mathbf{k}_*^\top & k_{**} \end{bmatrix}\right) \quad (6)$$

其中 $\mathbf{K}_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$, $\mathbf{k}_* = [k(\mathbf{x}_1, \mathbf{x}^*), \dots, k(\mathbf{x}_n, \mathbf{x}^*)]^\top$, $k_{**} = k(\mathbf{x}^*, \mathbf{x}^*)$ 。

进而利用多元高斯分布的条件分布性质，导出预测均值与预测方差：

$$\bar{y}^* = \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I}_n)^{-1} \mathbf{y} \quad (7)$$

$$\text{var}(y^*) = k_{**} - \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I}_n)^{-1} \mathbf{k}_* \quad (8)$$

预测均值的直观理解为：它是训练观测值 $\mathbf{y}$ 的加权线性组合，权重由待预测点与训练点的相似度 $\mathbf{k}_*$ 决定。预测方差则反映不确定性：当待预测点远离训练数据时， k_{**} 占主导，方差增大；当靠近训练数据时，第二项抵消更多，方差减小。

2.4 代码中的 alpha 噪声参数

在 sklearn 的 GaussianProcessRegressor 中，alpha 参数为加到核矩阵对角线上的额外数值，其作用有二：一是提升数值稳定性，防止核矩阵接近奇异时求逆失败；二是提供正则化，避免过拟合。需特别区分：核函数中的 WhiteKernel 噪声方差 σ_n^2 为概率模型的组成部分，经优化后为 0.1；而 alpha=1e-2 属于代码层面的数值补丁，不改变理论公式，仅影响实际计算。本研究所展示的理论公式仅包含 σ_n^2 ，该参数为概率模型所认可。

表 2: 16 种特征组合

序号	组合名称	特征变量
1	本 + 研 + 师	本科生, 研究生, 在编-教师
2	本 + 研 + 师 + 是否公课	本科生, 研究生, 在编-教师, 是否公共课
3	本 + 研 + 师 + 公课数量	本科生, 研究生, 在编-教师, 公共课数量
4	本 + 研 + 师 + 公课学分	本科生, 研究生, 在编-教师, 公共课学分
5	本 + 研 + 师 + 留 + 公课学分	本科生, 研究生, 在编-教师, 留学生, 公共课学分
6	本 + 研 + 师 + 留 + 公课数量	本科生, 研究生, 在编-教师, 留学生, 公共课数量
7	本 + 研 + 师 + 留	本科生, 研究生, 在编-教师, 留学生
8	本 + 研 + 师 + 留 + 是否公课	本科生, 研究生, 在编-教师, 留学生, 是否公共课
9	本 + 研 + 师 + 长留	本科生, 研究生, 在编-教师, 长期留学生
10	本 + 研 + 师 + 长留 + 公课学分	本科生, 研究生, 在编-教师, 长期留学生, 公共课学分
11	本 + 研 + 师 + 长留 + 公课数量	本科生, 研究生, 在编-教师, 长期留学生, 公共课数量
12	本 + 研 + 师 + 长留 + 是否公课	本科生, 研究生, 在编-教师, 长期留学生, 是否公共课
13	折合学生数 + 公课数量	折合学生数, 公共课数量
14	折合学生数 + 公课学分	折合学生数, 公共课学分
15	折合学生数 + 是否公课	折合学生数, 是否公共课
16	折合学生数	折合学生数

2.5 多特征组合策略

本研究共构建 16 种特征组合，如表 2所示。

组合规则如下：第一，基础特征为”本科生 + 研究生 + 在编教师”或”折合学生数”，二者择一；第二，公共课相关变量（学分、数量、是否公共课）至多选取一个；第三，留学生与长期留学生至多选取一个。最优组合为”本 + 研 + 师”（MAE 最低）与”本 + 研 + 师 + 是否公课”（ R^2 最高）。值得注意的是，所有包含”折合学生数”的组合（13-16）表现明显较差，表明折合学生数作为单一替代指标无法充分捕捉各学院管理工作量的差异。所有 16 种组合共用相同的核函数配置，区别在于特征维度不同，从而保证了结果的可比性。

3 假设检验与精度验证

3.1 验证方法

模型构建完成后，需对其可靠性进行系统验证。与以往仅验证单一模型的做法不同，本研究对 16 种特征组合分别实施了四层验证：配对 t 检验用于判断均值是否一致，F 检验与 Levene 检验用于判断方差是否齐性，同时辅以 MAE、RMSE、 R^2 等精度指标。验证结果表明：所有 16 种组合均通过了三项假设检验，说明 GPR 模型在多种特征配置下均具有统计可靠性。

3.2 假设检验与精度指标（最优两组）

两组最优组合的详细验证结果如表 3所示。

表 3: 最优两组假设检验与精度指标

检验/指标	组合 1: 本 + 研 + 师	组合 2: 本 + 研 + 师 + 是否公课
配对 t 检验 (p 值)	0.373 (通过)	0.505 (通过)
F 检验 (p 值)	0.295 (通过)	0.468 (通过)
Levene 检验 (p 值)	0.482 (通过)	0.603 (通过)
MAE	1.408	1.408
RMSE	2.312	2.312
MAPE	14.98%	16.82%
R^2	0.698	0.879

验证结果理想。两组最优组合的三项假设检验均获通过，p 值均远大于 0.05 的显著性水平。组合 1”本 + 研 + 师”的 MAE 最低 (0.454)，但 R^2 为 0.698；组合 2”本 + 研 + 师 + 是否公课”的 R^2 更高 (0.879)，MAE 略高 (0.538)。上述结果表明：仅采

用三个核心变量即可获得最低的预测偏差；加入“是否公共课”后，模型解释力显著提升，但偏差略有增加。两种组合各具优势，后续可根据实际需求进行选择。基于上述结果，可将模型外推至 2030 年。

4 预测结果与预算约束

4.1 GPR 预测结果与官方 OLS 拟合对比

本研究展示 2030 年 GPR 预测值与官方 OLS 拟合值的对比结果。从折线图与偏差图可以看出，大部分学院的 GPR 预测值与官方 OLS 结果高度吻合。最优组合（本 + 研 + 师）的散点图 R^2 达到 0.898，表明两种方法在整体趋势上高度一致。差异较大的点主要集中于文科学院及折合学生数组组合，上述学院特征变量波动较大，但最优组合的偏差仍处于可接受范围。该结果说明 GPR 不仅能给出合理的点预测，还能提供置信区间，该优势为 OLS 线性回归所不具备。

4.2 预算约束与层级拆分模型

预测结果生成后，需进一步考虑预算约束与层级拆分问题。与以往直接在总编制上进行拆分的做法不同，本研究设计了三步法。

Step 1: 预算约束（含组织员）

$$\hat{B}_i^{\text{约束}} = \begin{cases} \hat{B}_i, & \hat{B}_i \leq B_i^{\text{预算}} \\ B_i^{\text{预算}}, & \hat{B}_i > B_i^{\text{预算}} \end{cases} \quad (9)$$

Step 2: 扣除组织员

$$\hat{B}_i^{\text{非组织员}} = \max(0, \hat{B}_i^{\text{约束}} - O_i) \quad (10)$$

Step 3: 按 2 : 3 : 5 拆分正科、副科、科级以下

$$\hat{y}_{i,1} = 0.2 \cdot \hat{B}_i^{\text{非组织员}}, \quad \hat{y}_{i,2} = 0.3 \cdot \hat{B}_i^{\text{非组织员}}, \quad \hat{y}_{i,3} = 0.5 \cdot \hat{B}_i^{\text{非组织员}} \quad (11)$$

其经济学含义在于：组织员编制单独保留，不受拆分影响；超预算时，剩余三类编制同步等额缩减，而非仅削减某一类，从而最大限度保持原有层级结构，避免管理层级断层。

4.3 预算约束后的层级拆分

2030 年预测中，共有 7 个学院超预算：测绘与地理信息学院、航空航天与力学学院、人文学院、政治与国际关系学院、马克思主义学院、国际文化交流学院、法学院。上述学院具有以下共同特征：规模较小，近年来留学生或本科生增长较快，且官方 OLS

拟合值本身已接近或超过预算上限。该现象表明 GPR 预测（含组织员）与官方 OLS 在上述学院上高度一致，差异主要来源于预算约束而非模型分歧。约束后，上述学院统一按预算上限取值，先行扣除组织员，再按 2:3:5 拆分。全校总编制从约束前的预测值压缩至预算总量，符合总量控制要求。

5 其他预测方法的尝试与对比

5.1 尝试方法一：PCA 工作量 + 时序组合预测

在确定 GPR 方案之前，本研究尝试了多种传统方法。第一种为 PCA 工作量与时序方法的组合预测：Q1 采用 PCA 提取综合职能强度，Q2 采用指数平滑或趋势回归捕捉时间趋势，最终通过滚动窗口验证确定组合权重。研究设计了四个版本：A 与 D 采用指数平滑，B 与 C 采用趋势回归；定权策略分为独立权重与统一权重。尽管版本 A 与 D 的 R^2 超过 0.96，但模型结构复杂，滚动窗口长度敏感，外推至 2030 年时的可靠性存疑。版本 B 与 C 则存在二次项外推的边界不稳定问题。

5.2 尝试方法二：H、h + 趋势回归预测比例

第二种尝试将问题转化为比例分配。核心思路为：若总编制已知或可控，则关键在于预测各学院的占比。Q1 采用 PCA 的 H 指标预测比例，Q2 采用趋势回归预测历史比例变化，再进行组合定权。然而，该方法存在结构性问题：比例对 H 的分布极其敏感，若某学院 H 异常偏高，比例将严重失真；趋势回归在比例数据上同样存在边界不稳定问题；组合后还需重新归一化，误差累积明显。最终绝对编制数的偏差大于 GPR，且预算约束需以含组织员总量施加，操作复杂，因此予以放弃。

5.3 尝试方法三：比例稳定法 + 逐步回归

第三种尝试为比例稳定法。基本假设为：若某学院过去五年编制比例稳定，则未来亦保持稳定；不稳定学院则以逐步回归重新预测比例。然而实际操作中发现，五年数据波动较大，真正满足稳定条件的学院极少。逐步回归对比例这一受限因变量建模存在结构性缺陷，预测比例易出现负值或总和不为 1 的情况。加之二次规划的硬约束（含组织员总量守恒），分配结果与学校实际人事政策不符，最终效果不如 GPR。

5.4 尝试方法四：PCA 硬约束优化模型

最后一种尝试为直接用优化模型求解。目标函数为相对误差最小化，约束为总编制守恒与预算上限（含组织员）：

$$\begin{aligned} \min_{y_i} \quad & \sum_{i=1}^n \left(\frac{H_i/y_i - h_i^*}{h_i^*} \right)^2 \\ \text{s.t.} \quad & \sum_{i=1}^n y_i = B_{\text{total}}, \quad 0 < y_i \leq B_i^{\text{预算}} \end{aligned} \tag{12}$$

然而，硬约束导致分配僵化：当总编制守恒与预算上限冲突时，优化器将大型学院顶至预算上限，其余学院按误差均匀分配，该结果与学校实际的人事调配逻辑不符。此外，优化模型仅给出点估计，无法提供置信区间，不利于风险评估。综合以上四种尝试，GPR 在简洁性、可解释性、多特征组合灵活性及不确定性量化方面具有明显优势，最终被选为推荐方案。