

高校管理岗编制预测：高斯过程回归模型

2026 年 6 月 20 日

1.1 研究背景与目标

研究目标：预测 2030 年各学院管理岗编制人数（含组织员），并划分为正科、副科、科级以下。

核心方法：高斯过程回归（Gaussian Process Regression, GPR）

- 将编制人数视为多维度特征变量（本科生、研究生、在编教师、留学生/长期留学生、公共课相关变量、折合学生数）的非线性函数；
- 通过核函数刻画学院间的相似性，自动估计预测不确定性；
- 采用多特征组合策略，以 2025 年数据训练、2026 年数据验证，按与官方拟合值的 MAE 排序选取最优组合。

验证策略：

训练集（2025 年） $\xrightarrow{\text{GPR 拟合}}$ 验证集（2026 年） $\xrightarrow{\text{假设检验}}$ 2030 年预测

1.2 符号说明

符号	含义
i	学院索引, $i = 1, 2, \dots, n$ ($n = 27$, 排除 2 个特殊学院)
t	年份索引, $t = 2025, 2026, 2030$
$\mathbf{x}_i$	第 i 个学院的特征向量 (3–5 维, 视组合而定)
O_i	第 i 个学院的组织员人数
$B_{i,t}$	第 i 个学院第 t 年的实际编制人数 (含组织员)
$\hat{B}_{i,t}$	GPR 预测编制人数 (含组织员)
$\hat{B}_i^{\text{约束}}$	预算约束后含组织员的编制人数
$\hat{B}_i^{\text{非组织员}}$	约束后非组织员编制人数, $\hat{B}_i^{\text{非组织员}} = \hat{B}_i^{\text{约束}} - O_i$
$f(\mathbf{x})$	潜在编制人数函数, 服从高斯过程
$\mu(\mathbf{x}^*)$	GPR 预测均值函数
$\sigma^2(\mathbf{x}^*)$	GPR 预测方差 (不确定性)
$B_i^{\text{预算}}$	预算约束人数 (含组织员)
$\alpha_1, \alpha_2, \alpha_3$	正科、副科、科级以下拆分比例 (0.2, 0.3, 0.5)

2.1 高斯过程

基本假设：编制人数潜在函数 $f(\mathbf{x})$ 服从一个高斯过程：

$$f(\mathbf{x}) \sim \mathcal{GP}(m(\mathbf{x}), k(\mathbf{x}, \mathbf{x}'))$$

均值函数（此处取零均值或数据均值）：

$$m(\mathbf{x}) = \mathbb{E}[f(\mathbf{x})]$$

协方差函数（核函数）：采用 RBF + 白噪声核

$$k(\mathbf{x}, \mathbf{x}') = \sigma^2 \exp\left(-\frac{\|\mathbf{x} - \mathbf{x}'\|^2}{2\ell^2}\right) + \sigma_n^2 \delta(\mathbf{x}, \mathbf{x}')$$

关键优势

GPR 不仅给出点预测 $\mu(\mathbf{x}^*)$ ，还给出**预测区间** $\mu(\mathbf{x}^*) \pm 1.96\sigma(\mathbf{x}^*)$ ，天然适合编制规划的风险评估。

2.2 最大化边际似然确定超参数

边际似然：给定数据与超参数时观察到函数值的概率

$$p(\mathbf{y} \mid \mathbf{X}) = \int p(\mathbf{y} \mid \mathbf{f}) p(\mathbf{f} \mid \mathbf{X}) d\mathbf{f} = \mathcal{N}(\mathbf{0}, \mathbf{K} + \sigma_n^2 \mathbf{I}_n)$$

对数边际似然：

$$\log p(\mathbf{y} \mid \mathbf{X}) = -\frac{1}{2} \mathbf{y}^\top (\mathbf{K} + \sigma_n^2 \mathbf{I}_n)^{-1} \mathbf{y} - \frac{1}{2} \log |\mathbf{K} + \sigma_n^2 \mathbf{I}_n| - \frac{n}{2} \log 2\pi$$

超参数优化：通过最大化 $\log p(\mathbf{y} \mid \mathbf{X})$ 确定 $\theta = (\sigma^2, \ell, \sigma_n^2)$ ，优化器采用 L-BFGS-B，配合 50 次随机重启。

2.3 预测函数的推导

联合分布：对训练输出 y 与待预测点 $\mathbf{x}^*$ 的函数值 y^* ，构造联合高斯分布

$$\begin{bmatrix} \mathbf{y} \\ y^* \end{bmatrix} \sim \mathcal{N}\left(\mathbf{0}, \begin{bmatrix} \mathbf{K} + \sigma_n^2 \mathbf{I}_n & \mathbf{k}_* \\ \mathbf{k}_*^\top & k_{**} \end{bmatrix}\right)$$

其中 $\mathbf{K}_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$ ， $\mathbf{k}_* = [k(\mathbf{x}_1, \mathbf{x}^*), \dots, k(\mathbf{x}_n, \mathbf{x}^*)]^\top$ ， $k_{**} = k(\mathbf{x}^*, \mathbf{x}^*)$ 。

预测均值：

$$\bar{y}^* = \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I}_n)^{-1} \mathbf{y}$$

预测方差：

$$\text{var}(y^*) = k_{**} - \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I}_n)^{-1} \mathbf{k}_*$$

2.4 代码中的 alpha 噪声参数

在 sklearn 的 GaussianProcessRegressor 中, $\alpha=1e-2$ 对应的是**附加噪声方差**的数值。

与核函数噪声的关系：核函数中 WhiteKernel 的 σ_n^2 经优化后为 0.1000, 而 $\alpha=1e-2$ 提供额外的正则化项。实际预测时, 总噪声矩阵为

$$\mathbf{K}_{\text{总}} = \mathbf{K} + (\sigma_n^2 + \alpha)\mathbf{I}_n$$

2.5 模型拟合结果与最终预测函数

多特征组合策略：共 16 种特征组合，完整结果如下表：

序号	组合名称	特征变量
1	本 + 研 + 师	本科生, 研究生, 在编-教师
2	本 + 研 + 师 + 是否公课	本科生, 研究生, 在编-教师, 是否公共课
3	本 + 研 + 师 + 公课数量	本科生, 研究生, 在编-教师, 公共课数量
4	本 + 研 + 师 + 公课学分	本科生, 研究生, 在编-教师, 公共课学分
5	本 + 研 + 师 + 留 + 公课学分	本科生, 研究生, 在编-教师, 留学生, 公共课学分
6	本 + 研 + 师 + 留 + 公课数量	本科生, 研究生, 在编-教师, 留学生, 公共课数量
7	本 + 研 + 师 + 留	本科生, 研究生, 在编-教师, 留学生
8	本 + 研 + 师 + 留 + 是否公课	本科生, 研究生, 在编-教师, 留学生, 是否公共课
9	本 + 研 + 师 + 长留	本科生, 研究生, 在编-教师, 长期留学生
10	本 + 研 + 师 + 长留 + 公课学分	本科生, 研究生, 在编-教师, 长期留学生, 公共课学分
11	本 + 研 + 师 + 长留 + 公课数量	本科生, 研究生, 在编-教师, 长期留学生, 公共课数量
12	本 + 研 + 师 + 长留 + 是否公课	本科生, 研究生, 在编-教师, 长期留学生, 是否公共课
13	折合学生数 + 公课数量	折合学生数, 公共课数量
14	折合学生数 + 公课学分	折合学生数, 公共课学分
15	折合学生数 + 是否公课	折合学生数, 是否公共课
16	折合学生数	折合学生数

2.5 最优两组预测函数（续）

最优组合 1：本 + 研 + 师 (MAE=0.454, 含组织员预测)

信号方差 σ^2	长度尺度 ℓ	噪声方差 σ_n^2
1.1576	2.9821	0.1000

最终预测均值函数：

$$\mu(\mathbf{x}^*) = \mathbf{k}_*^\top (\mathbf{K} + 0.1000 \cdot \mathbf{I}_n)^{-1} \mathbf{y}$$

最终预测方差函数：

$$\sigma^2(\mathbf{x}^*) = 1.1576 - \mathbf{k}_*^\top (\mathbf{K} + 0.1000 \cdot \mathbf{I}_n)^{-1} \mathbf{k}_*$$

其中 $\mathbf{K}_{ij} = 1.1576 \exp(-\|\mathbf{x}_i - \mathbf{x}_j\|^2/17.7857)$, $\mathbf{k}_*$ 为待预测点与训练点的协方差向量。

2.5 最优两组预测函数（续）

最优组合 2：本 + 研 + 师 + 是否公课（MAE=0.538，含组织员预测）

信号方差 σ^2	长度尺度 ℓ	噪声方差 σ_n^2
1.1576	2.9821	0.1000

最终预测均值函数：

$$\mu(\mathbf{x}^*) = \mathbf{k}_*^\top (\mathbf{K} + 0.1000 \cdot \mathbf{I}_n)^{-1} \mathbf{y}$$

最终预测方差函数：

$$\sigma^2(\mathbf{x}^*) = 1.1576 - \mathbf{k}_*^\top (\mathbf{K} + 0.1000 \cdot \mathbf{I}_n)^{-1} \mathbf{k}_*$$

说明

两组最优组合共用相同的核函数配置，区别在于特征维度：组合 1 为 3 维（本、研、师），组合 2 为 4 维（增加是否公共课 0-1 变量）。

3.1 验证方法

以 2025 年数据训练（已补齐在编教师数据）、2026 年数据验证，对 16 种 GPR 特征组合分别进行统计检验：

- ① 配对 t 检验：检验预测值与实际值的均值差异， $H_0 : \mu_{\text{pred}} = \mu_{\text{actual}}$ ；
- ② F 检验：检验预测值与实际值的方差齐性， $H_0 : \sigma_{\text{pred}}^2 = \sigma_{\text{actual}}^2$ ；
- ③ Levene 检验：方差齐性稳健检验；
- ④ 精度指标：MAE、RMSE、MAPE、 R^2 。

说明

所有 16 种特征组合均通过三项假设检验，验证了 GPR 模型在多种特征配置下的统计可靠性。以下重点展示最优两组的检验结果。

3.2 假设检验与精度指标（最优两组）

组合 1：本 + 研 + 师 (MAE=0.454)

检验/指标	结果
配对 t 检验 (p 值)	0.373 (通过)
F 检验 (p 值)	0.295 (通过)
Levene 检验 (p 值)	0.482 (通过)
MAE	1.408
RMSE	2.312
MAPE	14.98%
R^2	0.698

组合 2：本 + 研 + 师 + 是否公课 (MAE=0.538)

检验/指标	结果
配对 t 检验 (p 值)	0.505 (通过)
F 检验 (p 值)	0.468 (通过)
Levene 检验 (p 值)	0.603 (通过)
MAE	1.408
RMSE	2.312
MAPE	16.82%
R^2	0.879

基本可行性判断：

- 两组最优组合的三项假设检验均通过，说明 GPR 预测值与 2026 年实际编制在均值和方差上均无显著差异；
- 组合 1 MAE 最低 (0.454)， $R^2 = 0.698$ ；组合 2 R^2 更高 (0.879)，MAE 略高 (0.538)。

4.1 预算约束与层级拆分模型

对第 i 个学院，设 GPR 预测总编制（含组织员）为 $\hat{B}_i$ ，预算上限（含组织员）为 $B_i^{\text{预算}}$ ，组织员人数为 O_i 。

Step 1: 预算约束（含组织员）

$$\hat{B}_i^{\text{约束}} = \begin{cases} \hat{B}_i, & \hat{B}_i \leq B_i^{\text{预算}} \\ B_i^{\text{预算}}, & \hat{B}_i > B_i^{\text{预算}} \end{cases}$$

Step 2: 扣除组织员

$$\hat{B}_i^{\text{非组织员}} = \max(0, \hat{B}_i^{\text{约束}} - O_i)$$

Step 3: 按 2 : 3 : 5 拆分正科、副科、科级以下

$$\hat{y}_{i,1} = 0.2 \cdot \hat{B}_i^{\text{非组织员}}, \quad \hat{y}_{i,2} = 0.3 \cdot \hat{B}_i^{\text{非组织员}}, \quad \hat{y}_{i,3} = 0.5 \cdot \hat{B}_i^{\text{非组织员}}$$

4.2 预算约束后的层级拆分

超预算学院 (7 个)：测绘与地理信息学院、航空航天与力学学院、人文学院、政治与国际关系学院、马克思主义学院、国际文化交流学院、法学院。

说明

上述 7 个学院的 GPR 预测值（含组织员）与官方 OLS 拟合结果基本一致；由于预测值超出预算上限，约束后均按**预算上限**取值，先扣除组织员人数，再按 2:3:5 拆分为正科、副科、科级以下。

5.1 尝试方法一：PCA 工作量 + 时序组合预测

方法框架：

- Q1：PCA 职能强度法（本科生、研究生、在编教师 → 综合指标 H → 反推编制）；
- Q2：指数平滑法（Holt）或趋势回归（BIC 选优）；
- 组合：滚动窗口验证 + 方差倒数法定权（独立权重或统一权重）。

四策略版本：

Q2 时序 \ 定权策略	独立权重	统一权重
指数平滑法（Holt）	版本 A	版本 D
趋势回归（BIC 选优）	版本 B	版本 C

5.2 尝试方法二：H、h + 趋势回归预测比例

核心思想：将编制预测转化为比例分配问题，用 PCA 的 H 和 h 框架结合趋势回归预测各学院占比。

实现步骤：

- ① Q1（比例预测）：用 2025 年数据训练 PCA，计算综合职能强度 H_i ，预测比例为

$$r_i^{Q1} = \frac{H_i}{\sum_{j=1}^n H_j}$$

- ② Q2（趋势回归）：对各学院 2022–2026 年的历史编制比例做趋势回归（年份一次项 + 二次项，BIC 选模），外推 2030 年比例 r_i^{Q2} ；
- ③ 组合定权：以 2025→2026 的验证误差确定统一权重 w^{Q1}, w^{Q2} ，组合得

$$r_i = w^{Q1} r_i^{Q1} + w^{Q2} r_i^{Q2}$$

- ④ 总量分配：以 2026 年总编制为基准， $B_i = r_i \cdot B_{\text{total}}$ ，再施加预算约束（含组织员）。

5.3 尝试方法三：比例稳定法 + 逐步回归

核心思想：若学院编制比例稳定，则保持 2026 年比例；不稳定学院用逐步回归预测比例。

实现步骤：

- ① 计算 2022–2026 年各学院编制占比，判断稳定性（变异系数 $CV < 0.15$ 且最大变化 < 0.015 ）；
- ② 稳定学院：直接沿用 2026 年比例；
- ③ 不稳定学院：以 5 维特征训练逐步回归预测比例；
- ④ 优化调整：在总编制守恒 + 预算约束（含组织员）下求解二次规划。

5.4 尝试方法四：PCA 硬约束优化模型

模型设定：

$$\begin{aligned} \min_{y_i} \quad & \sum_{i=1}^n \left(\frac{H_i/y_i - h_i^*}{h_i^*} \right)^2 \\ \text{s.t.} \quad & \sum_{i=1}^n y_i = B_{\text{total}}, \quad 0 < y_i \leq B_i^{\text{预算}} \end{aligned}$$