

高校管理岗编制预测：高斯过程回归模型

2026 年 6 月 25 日

1 模型概述

1.1 研究背景与目标

高校管理岗编制预测涉及人事规划，需兼顾职能强度与预算约束。本研究采用多特征组合策略，候选特征涵盖本科生、研究生、在编教师、留学生/长期留学生、公共课相关变量（学分、数量、是否公共课）以及折合学生数。通过系统组合，共构建 16 种特征组合，以 2030 年预测与官方拟合值的 MAE 为排序依据，选取最优组合进行展示。验证策略采用“训练—验证—预测”三步框架：以 2025 年数据（已补齐在编教师）训练模型，2026 年实际数据验证模型精度，经统计检验后外推至 2030 年，以保障外推可信度。

研究目标为预测 2030 年各学院管理岗编制人数（含组织员），并划分为正科、副科、科级以下。核心方法为高斯过程回归（Gaussian Process Regression, GPR），其特点在于：将编制人数视为多维度特征变量的非线性函数；通过核函数刻画学院间的相似性，自动估计预测不确定性；采用多特征组合策略，以 2025 年数据训练、2026 年数据验证，按与官方拟合值的 MAE 排序选取最优组合。

2 GPR 方法原理

2.1 高斯过程

高斯过程回归的核心思想在于，不直接预设编制人数与特征之间的具体函数形式（如线性或二次），而是假设该函数服从高斯过程。由此，任意有限个输入点对应的函数值联合服从多元高斯分布：

$$f(\mathbf{x}) \sim \mathcal{GP}(m(\mathbf{x}), k(\mathbf{x}, \mathbf{x}')) \quad (1)$$

均值函数（此处取零均值）为：

$$m(\mathbf{x}) = \mathbb{E}[f(\mathbf{x})] \quad (2)$$

协方差函数（核函数）采用 RBF 核与白噪声核的组合：

$$k(\mathbf{x}, \mathbf{x}') = \sigma^2 \exp\left(-\frac{\|\mathbf{x} - \mathbf{x}'\|^2}{2\ell^2}\right) + \sigma_n^2 \delta(\mathbf{x}, \mathbf{x}') \quad (3)$$

RBF 核的直观含义为，两学院特征越接近，其编制人数越相似；白噪声项则用于捕捉观测误差。GPR 的显著优势在于其天然提供预测区间 $\mu(\mathbf{x}^*) \pm 1.96\sigma(\mathbf{x}^*)$ ，该特性对于编制规划具有重要意义——不仅需获取点预测值，还需量化预测的不确定性。

2.2 最大化边际似然确定超参数

边际似然可理解为：给定超参数时，观察到现有训练数据的概率。通过对潜在函数积分消去后，得到多元高斯分布：

$$p(\mathbf{y} | \mathbf{X}) = \int p(\mathbf{y} | \mathbf{f}) p(\mathbf{f} | \mathbf{X}) d\mathbf{f} = \mathcal{N}(\mathbf{0}, \mathbf{K} + \sigma_n^2 \mathbf{I}_n) \quad (4)$$

直接最大化边际似然存在数值困难——概率值极小，易导致浮点数下溢。因此取对数处理：

$$\log p(\mathbf{y} | \mathbf{X}) = -\frac{1}{2} \mathbf{y}^\top (\mathbf{K} + \sigma_n^2 \mathbf{I}_n)^{-1} \mathbf{y} - \frac{1}{2} \log |\mathbf{K} + \sigma_n^2 \mathbf{I}_n| - \frac{n}{2} \log 2\pi \quad (5)$$

优化器采用 L-BFGS-B，配合 50 次随机重启，以避免陷入局部最优。最终确定的三个超参数分别为信号方差、长度尺度与噪声方差。

2.3 预测函数的推导

将训练输出与待预测点的输出联合构造高斯分布：

$$\begin{bmatrix} \mathbf{y} \\ y^* \end{bmatrix} \sim \mathcal{N}\left(\mathbf{0}, \begin{bmatrix} \mathbf{K} + \sigma_n^2 \mathbf{I}_n & \mathbf{k}_* \\ \mathbf{k}_*^\top & k_{**} \end{bmatrix}\right) \quad (6)$$

其中 $\mathbf{K}_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$ ， $\mathbf{k}_* = [k(\mathbf{x}_1, \mathbf{x}^*), \dots, k(\mathbf{x}_n, \mathbf{x}^*)]^\top$ ， $k_{**} = k(\mathbf{x}^*, \mathbf{x}^*)$ 。

进而利用多元高斯分布的条件分布性质，导出预测均值与预测方差：

$$\bar{y}^* = \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I}_n)^{-1} \mathbf{y} \quad (7)$$

$$\text{var}(y^*) = k_{**} - \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I}_n)^{-1} \mathbf{k}_* \quad (8)$$

预测均值的直观理解为：它是训练观测值 $\mathbf{y}$ 的加权线性组合，权重由待预测点与训练点的相似度 $\mathbf{k}_*$ 决定。预测方差则反映不确定性：当待预测点远离训练数据时， k_{**} 占主导，方差增大；当靠近训练数据时，第二项抵消更多，方差减小。

2.4 代码中的 alpha 噪声参数

在 sklearn 的 GaussianProcessRegressor 中, $\alpha=1e-2$ 对应的是附加噪声方差的数值, 其值越小代表越信任数据, 越大代表越不信任数据, 取值一般为 $1 \sim 1e-6$ 。

需特别区分核函数噪声与 α 参数的关系: 核函数中 WhiteKernel 的噪声方差 σ_n^2 经优化后为 0.1000, 而 $\alpha=1e-2$ 提供额外的正则化项。实际预测时, 总噪声矩阵为

$$\mathbf{K}_{\text{总}} = \mathbf{K} + (\sigma_n^2 + \alpha)\mathbf{I}_n \quad (9)$$

本研究所展示的理论公式仅包含 σ_n^2 , 该参数为概率模型所认可; α 属于代码层面的数值补丁, 不改变理论公式, 仅影响实际计算。

2.5 多特征组合策略

本研究共构建 16 种特征组合, 如表 1 所示。

表 1: 16 种特征组合

序号	组合名称	特征变量
1	本 + 研 + 师	本科生, 研究生, 在编-教师
2	本 + 研 + 师 + 是否公课	本科生, 研究生, 在编-教师, 是否公共课
3	本 + 研 + 师 + 公课数量	本科生, 研究生, 在编-教师, 公共课数量
4	本 + 研 + 师 + 公课学分	本科生, 研究生, 在编-教师, 公共课学分
5	本 + 研 + 师 + 留 + 公课学分	本科生, 研究生, 在编-教师, 留学生, 公共课学分
6	本 + 研 + 师 + 留 + 公课数量	本科生, 研究生, 在编-教师, 留学生, 公共课数量
7	本 + 研 + 师 + 留	本科生, 研究生, 在编-教师, 留学生
8	本 + 研 + 师 + 留 + 是否公课	本科生, 研究生, 在编-教师, 留学生, 是否公共课
9	本 + 研 + 师 + 长留	本科生, 研究生, 在编-教师, 长期留学生
10	本 + 研 + 师 + 长留 + 公课学分	本科生, 研究生, 在编-教师, 长期留学生, 公共课学分
11	本 + 研 + 师 + 长留 + 公课数量	本科生, 研究生, 在编-教师, 长期留学生, 公共课数量
12	本 + 研 + 师 + 长留 + 是否公课	本科生, 研究生, 在编-教师, 长期留学生, 是否公共课
13	折合学生数 + 公课数量	折合学生数, 公共课数量
14	折合学生数 + 公课学分	折合学生数, 公共课学分
15	折合学生数 + 是否公课	折合学生数, 是否公共课
16	折合学生数	折合学生数

组合规则如下: 第一, 基础特征为”本科生 + 研究生 + 在编教师”或”折合学生数”, 二者择一; 第二, 公共课相关变量(学分、数量、是否公共课)至多选取一个; 第三, 留学生与长期留学生至多选取一个。最优组合为”本 + 研 + 师 + 是否公课”。值得

注意的是，所有包含”折合学生数”的组合（13–16）表现明显较差，表明折合学生数作为单一替代指标无法充分捕捉各学院管理工作量的差异。所有 16 种组合共用相同的核函数配置，区别在于特征维度不同，从而保证了结果的可比性。

2.6 最优预测函数

基于”本 + 研 + 师 + 是否公课”组合，经 L-BFGS-B 优化器 50 次随机重启后，确定的最优超参数如表 2 所示。

表 2: 最优超参数估计值

信号方差 σ^2	长度尺度 ℓ	噪声方差 σ_n^2
1.6379	3.7832	0.1000

将上述超参数代入预测公式，得到最终预测均值函数：

$$\mu(\mathbf{x}^*) = \mathbf{k}_*^\top (\mathbf{K} + 0.1000 \cdot \mathbf{I}_n)^{-1} \mathbf{y} \quad (10)$$

以及最终预测方差函数：

$$\sigma^2(\mathbf{x}^*) = 1.6379 - \mathbf{k}_*^\top (\mathbf{K} + 0.1000 \cdot \mathbf{I}_n)^{-1} \mathbf{k}_* \quad (11)$$

2.7 矩阵 $\mathbf{K}$ 、 $\mathbf{k}_*$ 、 k_{**} 的详细说明

为便于理解预测函数中各矩阵的构造方式，以下对 $\mathbf{K}$ 、 $\mathbf{k}_*$ 、 k_{**} 逐一说明。

训练核矩阵 $\mathbf{K}$ ($n \times n$, n 为训练样本数) 的元素由核函数计算：

$$\mathbf{K}_{ij} = k(\mathbf{x}_i, \mathbf{x}_j) = \sigma^2 \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\ell^2}\right) \quad (12)$$

其中 $\mathbf{x}_i, \mathbf{x}_j$ 为训练样本的特征向量。以本研究为例， $n = 27$ （排除 2 个特殊学院）， $\sigma^2 = 1.6379$, $\ell = 3.7832$, 故 $\mathbf{K}$ 为 27×27 的对称正定矩阵，对角线元素 $\mathbf{K}_{ii} = \sigma^2 = 1.6379$ （因 $\|\mathbf{x}_i - \mathbf{x}_i\| = 0$ ，指数项为 1）。非对角线元素随两学院特征向量欧氏距离增大而衰减，体现了”相似学院编制相似”的平滑先验。

训练-预测协方差向量 $\mathbf{k}_*$ ($n \times 1$) 的元素为待预测学院与每个训练学院的核函数值：

$$\mathbf{k}_* = [k(\mathbf{x}_1, \mathbf{x}^*), k(\mathbf{x}_2, \mathbf{x}^*), \dots, k(\mathbf{x}_n, \mathbf{x}^*)]^\top \quad (13)$$

其中 $\mathbf{x}^*$ 为待预测学院（2026 年或 2030 年）的特征向量。当 $\mathbf{x}^*$ 与某训练学院 $\mathbf{x}_i$ 特征接近时， $k(\mathbf{x}_i, \mathbf{x}^*)$ 接近 σ^2 ，该训练学院在预测中的权重增大；反之权重减小。这一机制使 GPR 天然具备局部插值特性。

预测点自协方差 k_{**} （标量）为：

$$k_{**} = k(\mathbf{x}^*, \mathbf{x}^*) = \sigma^2 = 1.6379 \quad (14)$$

即预测点与自身的协方差，恒等于信号方差。在预测方差公式中， k_{**} 为方差上限，第二项 $\mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I}_n)^{-1} \mathbf{k}_*$ 为训练数据提供的信息增益，二者之差即为预测不确定性。当训练数据充足且待预测点靠近训练区域时，信息增益接近 k_{**} ，方差趋近于零；反之方差接近 k_{**} 。

2.8 2026 年各学院预测结果

以 2026 年数据为预测集（即自预测），”本 + 研 + 师 + 是否公课”组合下各学院的预测结果如表 3 至表 6 所示。表中同时给出预测标准差与 95% 置信区间。

表 3: 2026 年自预测结果（一）

学院	实际	预测	标准差	95% 区间
物理科学与工程学院	6	9.91	0.89	[8.17, 11.65]
数学科学学院	6	7.10	0.71	[5.71, 8.49]
化学科学与工程学院	7	6.73	0.70	[5.36, 8.10]
海洋与地球科学学院	8	8.47	0.73	[7.04, 9.90]
生命科学与技术学院	8	10.47	0.82	[8.86, 12.08]
机械工程与机器人学院	11	9.28	0.81	[7.69, 10.87]
测绘与地理信息学院	5	6.39	0.71	[5.00, 7.78]
计算机科学与技术学院（软件学院）	12	12.73	0.91	[10.95, 14.51]
汽车与能源学院	11	13.70	0.92	[11.90, 15.50]
材料科学与工程学院	9	9.75	0.84	[8.10, 11.40]
电子与信息工程学院	16	17.54	1.03	[15.52, 19.56]
环境科学与工程学院	17	16.33	0.98	[14.41, 18.25]

表 4: 2026 年自预测结果（二）

学院	实际	预测	标准差	95% 区间
土木工程学院	27	26.62	1.26	[24.15, 29.09]
交通学院（铁道与城市轨道交通研究院）	20	18.84	1.07	[16.74, 20.94]
建筑与城市规划学院	20	19.86	1.10	[17.70, 22.02]
航空航天与力学学院	7	7.50	0.76	[6.01, 8.99]
中德工程学院，职业技术教育学院	5	5.00	0.68	[3.67, 6.33]
医学院	22	21.55	1.16	[19.28, 23.82]
设计创意学院	9	6.66	0.70	[5.29, 8.03]
人文学院	7	7.71	0.76	[6.22, 9.20]
外国语学院	12	10.41	0.83	[8.78, 12.04]
经济与管理学院	22	17.23	1.05	[15.17, 19.29]
政治与国际关系学院	3	5.80	0.72	[4.39, 7.21]
艺术与传媒学院	7	6.92	0.71	[5.53, 8.31]

表中 95% 置信区间的计算公式为 [预测值 - 1.96 × 标准差, 预测值 + 1.96 × 标准差]。正科、副科、科级以下的分配公式为 (预测值 - 组织员) × (0.2, 0.3, 0.5)。对于全 0 特征学院（如医学与生命科学部等），直接取 2026 年现值作为预测值，标准差为 GPR 训练样本的标准差估计。

表 5: 2026 年自预测结果（三）

学院	实际	预测	标准差	95% 区间
上海国际知识产权学院	4	5.31	0.73	[3.88, 6.74]
马克思主义学院	8	6.01	0.70	[4.64, 7.38]
国际文化交流学院	4	4.50	0.67	[3.19, 5.81]
法学院	6	6.17	0.71	[4.78, 7.56]
体育部（国际足球学院）	11	7.62	0.76	[6.13, 9.11]
医学与生命科学部	2	2.00	0	[2.00, 2.00]
出国培训学院，留德预备部	0	3.91	0.66	[2.62, 5.20]
网络教育学院，继续教育学院	9	3.98	0.66	[2.69, 5.27]
中德学院	3	3.76	0.65	[2.49, 5.03]
创新创业学院	8	3.76	0.65	[2.49, 5.03]
新生院	3	3.69	0.65	[2.42, 4.96]
国豪书院（未来技术学院）	8	6.73	0.71	[5.34, 8.12]

表 6: 2026 年自预测结果（四）

学院	实际	预测	标准差	95% 区间
国家卓越工程师学院，国际工程师学院	7	7.00	0	[7.00]
中意工程创新学院	4	4.00	0	[4.00, 4.00]
启迪书院	4	3.87	0.65	[2.60, 5.14]
口腔医学院	0	4.05	0.65	[2.78, 5.32]
上海自主智能无人系统科学中心	11	5.21	0.70	[3.84, 6.58]
同济大学上海国际设计创新学院	0	4.11	0.65	[2.84, 5.38]

3 假设检验与精度验证

3.1 验证方法

模型构建完成后，需对其可靠性进行系统验证。与以往仅验证单一模型的做法不同，本研究对 16 种特征组合分别实施了四层验证：配对 t 检验用于判断均值是否一致，F 检验与 Levene 检验用于判断方差是否齐性，同时辅以 MAE、RMSE、 R^2 等精度指标。验证结果表明：所有 16 种组合均通过了三项假设检验，说明 GPR 模型在多种特征配置下均具有统计可靠性。

3.2 假设检验与精度指标

以”本 + 研 + 师 + 是否公课”组合为例，其详细验证结果如表 7 所示。

验证结果理想。该组合的三项假设检验均获通过，p 值均远大于 0.05 的显著性水平。上述结果表明 GPR 模型在”本 + 研 + 师 + 是否公课”特征配置下具有统计可靠性。基于上述结果，可将模型外推至 2030 年。

表 7: 假设检验与精度指标 (组合: 本 + 研 + 师 + 是否公课)

检验/指标	结果
配对 t 检验 (p 值)	0.505 (通过)
F 检验 (p 值)	0.468 (通过)
Levene 检验 (p 值)	0.603 (通过)
MAE	1.666
RMSE	2.316
MAPE	21.143%
R^2	0.862
MAE_vs 参数 1	0.714

4 其他预测方法的尝试与对比

4.1 尝试方法一: PCA 工作量 + 时序组合预测

在确定 GPR 方案之前,本研究尝试了多种传统方法。第一种为 PCA 工作量与时序方法的组合预测: Q1 采用 PCA 提取综合职能强度, Q2 采用指数平滑或趋势回归捕捉时间趋势,最终通过滚动窗口验证确定组合权重。研究设计了四个版本: A 与 D 采用指数平滑, B 与 C 采用趋势回归; 定权策略分为独立权重与统一权重。尽管版本 A 与 D 的 R^2 超过 0.96, 但模型结构复杂, 滚动窗口长度敏感, 外推至 2030 年时的可靠性存疑。版本 B 与 C 则存在二次项外推的边界不稳定问题。

4.2 尝试方法二: H、h + 趋势回归预测比例

第二种尝试将问题转化为比例分配。核心思路为: 若总编制已知或可控, 则关键在于预测各学院的占比。Q1 采用 PCA 的 H 指标预测比例, Q2 采用趋势回归预测历史比例变化, 再进行组合定权。然而, 该方法存在结构性问题: 比例对 H 的分布极其敏感, 若某学院 H 异常偏高, 比例将严重失真; 趋势回归在比例数据上同样存在边界不稳定问题; 组合后还需重新归一化, 误差累积明显。最终绝对编制数的偏差大于 GPR, 且预算约束需以含组织员总量施加, 操作复杂, 因此予以放弃。

4.3 尝试方法三: 比例稳定法 + 逐步回归

第三种尝试为比例稳定法。基本假设为: 若某学院过去五年编制比例稳定, 则未来亦保持稳定; 不稳定学院则以逐步回归重新预测比例。然而实际操作中发现, 五年数据波动较大, 真正满足稳定条件的学院极少。逐步回归对比例这一受限因变量建模存在结构性缺陷, 预测比例易出现负值或总和不为 1 的情况。加之二次规划的硬约束 (含组织

员总量守恒), 分配结果与学校实际人事政策不符, 最终效果不如 GPR。

4.4 尝试方法四: PCA 硬约束优化模型

最后一种尝试为直接用优化模型求解。目标函数为相对误差最小化, 约束为总编制守恒与预算上限 (含组织员):

$$\begin{aligned} \min_{y_i} \quad & \sum_{i=1}^n \left(\frac{H_i/y_i - h_i^*}{h_i^*} \right)^2 \\ \text{s.t.} \quad & \sum_{i=1}^n y_i = B_{\text{total}}, \quad 0 < y_i \leq B_i^{\text{预算}} \end{aligned} \tag{15}$$

然而, 硬约束导致分配僵化: 当总编制守恒与预算上限冲突时, 优化器将大型学院顶至预算上限, 其余学院按误差均匀分配, 该结果与学校实际的人事调配逻辑不符。此外, 优化模型仅给出点估计, 无法提供置信区间, 不利于风险评估。综合以上四种尝试, GPR 在简洁性、可解释性、多特征组合灵活性及不确定性量化方面具有明显优势, 最终被选为推荐方案。