

高校管理岗编制预测：高斯过程回归模型

2026 年 6 月 25 日

1.1 研究背景与目标

研究目标：预测 2030 年各学院管理岗编制人数（含组织员），并划分为正科、副科、科级以下。

核心方法：高斯过程回归（Gaussian Process Regression, GPR）

- 将编制人数视为多维度特征变量（本科生、研究生、在编教师、留学生/长期留学生、公共课相关变量、折合学生数）的非线性函数；
- 通过核函数刻画学院间的相似性，自动估计预测不确定性；
- 采用多特征组合策略，以 2025 年数据训练、2026 年数据验证，按与官方拟合值的 MAE 排序选取最优组合。

优越性：

- 高斯过程回归作为一个适用于小样本的机器学习方法，不仅可以预测输出值，还可以提供预测区间。

2.1 高斯过程

基本假设： 编制人数潜在函数 $f(\mathbf{x})$ 服从一个高斯过程：

$$f(\mathbf{x}) \sim \mathcal{GP}(m(\mathbf{x}), k(\mathbf{x}, \mathbf{x}'))$$

均值函数（一般直接取零均值）：

$$m(\mathbf{x}) = \mathbb{E}[f(\mathbf{x})]$$

协方差函数（核函数）： 采用 RBF + 白噪声核

$$k(\mathbf{x}, \mathbf{x}') = \sigma^2 \exp\left(-\frac{\|\mathbf{x} - \mathbf{x}'\|^2}{2\ell^2}\right) + \sigma_n^2 \delta(\mathbf{x}, \mathbf{x}')$$

关键点

GPR 可通过不同超参数确定不同形态高斯过程，保证输出一定符合高斯过程。

2.2 最大化边际似然确定超参数

边际似然：给定数据与超参数时观察到函数值的概率

$$p(\mathbf{y} \mid \mathbf{X}) = \int p(\mathbf{y} \mid \mathbf{f}) p(\mathbf{f} \mid \mathbf{X}) d\mathbf{f} = \mathcal{N}(\mathbf{0}, \mathbf{K} + \sigma_n^2 \mathbf{I}_n)$$

对数边际似然：

$$\log p(\mathbf{y} \mid \mathbf{X}) = -\frac{1}{2} \mathbf{y}^\top (\mathbf{K} + \sigma_n^2 \mathbf{I}_n)^{-1} \mathbf{y} - \frac{1}{2} \log |\mathbf{K} + \sigma_n^2 \mathbf{I}_n| - \frac{n}{2} \log 2\pi$$

超参数优化：通过最大化 $\log p(\mathbf{y} \mid \mathbf{X})$ 确定 $\theta = (\sigma^2, \ell, \sigma_n^2)$ ，优化器采用 L-BFGS-B，配合 50 次随机重启保证找到全局最优解。

2.3 预测函数的推导

联合分布：由于待预测点函数值也符合高斯过程，可对训练输出 y 与待预测点 x^* 的函数值 y^* ，构造联合高斯分布

$$\begin{bmatrix} y \\ y^* \end{bmatrix} \sim \mathcal{N}\left(\mathbf{0}, \begin{bmatrix} \mathbf{K} + \sigma_n^2 \mathbf{I}_n & \mathbf{k}_* \\ \mathbf{k}_*^\top & k_{**} \end{bmatrix}\right)$$

其中 $\mathbf{K}_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$, $\mathbf{k}_* = [k(\mathbf{x}_1, \mathbf{x}^*), \dots, k(\mathbf{x}_n, \mathbf{x}^*)]^\top$, $k_{**} = k(\mathbf{x}^*, \mathbf{x}^*)$ 。

预测均值（即预测输出值）：

$$\bar{y}^* = \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I}_n)^{-1} \mathbf{y}$$

预测方差（用以确定预测区间）：

$$\text{var}(y^*) = k_{**} - \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I}_n)^{-1} \mathbf{k}_*$$

2.4 代码中的 alpha 噪声参数

在 sklearn 的 GaussianProcessRegressor 中，alpha=1e-2 对应的是**附加噪声方差**的数值，其值越小代表越信任数据，越大代表越不信任数据，取值一般为 1 1e-6。

与核函数噪声的关系：核函数中 WhiteKernel 的 σ_n^2 经优化后为 0.1000，而 alpha=1e-2 提供额外的正则化项。实际预测时，总噪声矩阵为

$$\mathbf{K}_{\text{总}} = \mathbf{K} + (\sigma_n^2 + \alpha)\mathbf{I}_n$$

2.5 模型拟合结果与最终预测函数

多特征组合策略：共 16 种特征组合，完整结果如下表：

序号	组合名称	特征变量
1	本 + 研 + 师	本科生, 研究生, 在编-教师
2	本 + 研 + 师 + 是否公课	本科生, 研究生, 在编-教师, 是否公共课
3	本 + 研 + 师 + 公课数量	本科生, 研究生, 在编-教师, 公共课数量
4	本 + 研 + 师 + 公课学分	本科生, 研究生, 在编-教师, 公共课学分
5	本 + 研 + 师 + 留 + 公课学分	本科生, 研究生, 在编-教师, 留学生, 公共课学分
6	本 + 研 + 师 + 留 + 公课数量	本科生, 研究生, 在编-教师, 留学生, 公共课数量
7	本 + 研 + 师 + 留	本科生, 研究生, 在编-教师, 留学生
8	本 + 研 + 师 + 留 + 是否公课	本科生, 研究生, 在编-教师, 留学生, 是否公共课
9	本 + 研 + 师 + 长留	本科生, 研究生, 在编-教师, 长期留学生
10	本 + 研 + 师 + 长留 + 公课学分	本科生, 研究生, 在编-教师, 长期留学生, 公共课学分
11	本 + 研 + 师 + 长留 + 公课数量	本科生, 研究生, 在编-教师, 长期留学生, 公共课数量
12	本 + 研 + 师 + 长留 + 是否公课	本科生, 研究生, 在编-教师, 长期留学生, 是否公共课
13	折合学生数 + 公课数量	折合学生数, 公共课数量
14	折合学生数 + 公课学分	折合学生数, 公共课学分
15	折合学生数 + 是否公课	折合学生数, 是否公共课
16	折合学生数	折合学生数

2.5 最优预测函数

最优组合：本 + 研 + 师 + 是否公课

信号方差 σ^2	长度尺度 ℓ	噪声方差 σ_n^2
1.6379	3.7832	0.1000

最终预测均值函数：

$$\mu(\mathbf{x}^*) = \mathbf{k}_*^\top (\mathbf{K} + 0.1000 \cdot \mathbf{I}_n)^{-1} \mathbf{y}$$

最终预测方差函数：

$$\sigma^2(\mathbf{x}^*) = 1.6379 - \mathbf{k}_*^\top (\mathbf{K} + 0.1000 \cdot \mathbf{I}_n)^{-1} \mathbf{k}_*$$

2.5 (续) 矩阵 $\mathbf{K}$ 、 $\mathbf{k}_*$ 、 k_{**} 的说明

训练核矩阵 $\mathbf{K}$ ($n \times n$, n 为训练样本数):

$$\mathbf{K}_{ij} = k(\mathbf{x}_i, \mathbf{x}_j) = \sigma^2 \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\ell^2}\right)$$

其中 $\mathbf{x}_i, \mathbf{x}_j$ 为训练样本的特征向量, $\sigma^2 = 1.6379$, $\ell = 3.7832$ 。

训练-预测协方差向量 $\mathbf{k}_*$ ($n \times 1$):

$$\mathbf{k}_* = [k(\mathbf{x}_1, \mathbf{x}^*), k(\mathbf{x}_2, \mathbf{x}^*), \dots, k(\mathbf{x}_n, \mathbf{x}^*)]^\top$$

其中 $\mathbf{x}^*$ 为待预测学院 (2026 年或 2030 年) 的特征向量。

预测点自协方差 k_{}** (标量):

$$k_{**} = k(\mathbf{x}^*, \mathbf{x}^*) = \sigma^2 = 1.6379$$

即预测点与自身的协方差, 等于信号方差。

2.5（续）各学院 2026 年预测结果（一）

学院	实际	预测	标准差	95% 区间
物理科学与工程学院	6	9.91	0.89	[8.17, 11.65]
数学科学学院	6	7.10	0.71	[5.71, 8.49]
化学科学与工程学院	7	6.73	0.70	[5.36, 8.10]
海洋与地球科学学院	8	8.47	0.73	[7.04, 9.90]
生命科学与技术学院	8	10.47	0.82	[8.86, 12.08]
机械工程与机器人学院	11	9.28	0.81	[7.69, 10.87]
测绘与地理信息学院	5	6.39	0.71	[5.00, 7.78]
计算机科学与技术学院（软件学院）	12	12.73	0.91	[10.95, 14.51]
汽车与能源学院	11	13.70	0.92	[11.90, 15.50]
材料科学与工程学院	9	9.75	0.84	[8.10, 11.40]
电子与信息工程学院	16	17.54	1.03	[15.52, 19.56]
环境科学与工程学院	17	16.33	0.98	[14.41, 18.25]

2.5（续）各学院 2026 年预测结果（二）

学院	实际	预测	标准差	95% 区间
土木工程学院	27	26.62	1.26	[24.15, 29.09]
交通学院（铁道与城市轨道交通研究院）	20	18.84	1.07	[16.74, 20.94]
建筑与城市规划学院	20	19.86	1.10	[17.70, 22.02]
航空航天与力学学院	7	7.50	0.76	[6.01, 8.99]
中德工程学院，职业技术教育学院	5	5.00	0.68	[3.67, 6.33]
医学院	22	21.55	1.16	[19.28, 23.82]
设计创意学院	9	6.66	0.70	[5.29, 8.03]
人文学院	7	7.71	0.76	[6.22, 9.20]
外国语学院	12	10.41	0.83	[8.78, 12.04]
经济与管理学院	22	17.23	1.05	[15.17, 19.29]
政治与国际关系学院	3	5.80	0.72	[4.39, 7.21]
艺术与传媒学院	7	6.92	0.71	[5.53, 8.31]

2.5（续）各学院 2026 年预测结果（三）

学院	实际	预测	标准差	95% 区间
上海国际知识产权学院	4	5.31	0.73	[3.88, 6.74]
马克思主义学院	8	6.01	0.70	[4.64, 7.38]
国际文化交流学院	4	4.50	0.67	[3.19, 5.81]
法学院	6	6.17	0.71	[4.78, 7.56]
体育部（国际足球学院）	11	7.62	0.76	[6.13, 9.11]
医学与生命科学部	2	2.00	0.61	[0.80, 3.20]
出国培训学院，留德预备部	0	3.91	0.66	[2.62, 5.20]
网络教育学院，继续教育学院	9	3.98	0.66	[2.69, 5.27]
中德学院	3	3.76	0.65	[2.49, 5.03]
创新创业学院	8	3.76	0.65	[2.49, 5.03]
新生院	3	3.69	0.65	[2.42, 4.96]
国豪书院（未来技术学院）	8	6.73	0.71	[5.34, 8.12]

2.5 (续) 各学院 2026 年预测结果 (四)

学院 科级以上	实际	预测	标准差	95% 区间	正科	副科
国家卓越工程师学院, 国际工程师学院	7	7.00	0.73	[5.57, 8.43]		
中意工程创新学院	4	4.00	0.65	[2.73, 5.27]		
启迪书院	4	3.87	0.65	[2.60, 5.14]		
口腔医学院	0	4.05	0.65	[2.78, 5.32]		
上海自主智能无人系统科学中心	11	5.21	0.70	[3.84, 6.58]		
同济大学上海国际设计创新学院	0	4.11	0.65	[2.84, 5.38]		

说明:

- 95% 预测区间 = [预测值 - 1.96 × 标准差, 预测值 + 1.96 × 标准差];
- 正科/副科/科级以上 = (预测值 - 组织员) × (0.2, 0.3, 0.5);
- 全 0 特征学院 (如医学与生命科学部等) 直接取 2026 年现值作为预测值, 标准差为 GPR 训练样本的标准差估计。

3.1 验证方法

以 2025 年数据训练、2026 年数据验证，对 16 种 GPR 特征组合分别进行统计检验：

- ① 配对 t 检验：检验预测值与实际值的均值差异， $H_0 : \mu_{\text{pred}} = \mu_{\text{actual}}$ ；
- ② F 检验：检验预测值与实际值的方差齐性， $H_0 : \sigma_{\text{pred}}^2 = \sigma_{\text{actual}}^2$ ；
- ③ Levene 检验：方差齐性稳健检验；
- ④ 精度指标：MAE、RMSE、MAPE、 R^2 。

说明

所有 16 种特征组合均通过三项假设检验，验证了 GPR 模型在多种特征配置下的统计可靠性。以下重点展示最优两组的检验结果。

3.2 假设检验与精度指标

组合：本 + 研 + 师 + 是否公课

检验/指标	结果
配对 t 检验 (p 值)	0.505 (通过)
F 检验 (p 值)	0.468 (通过)
Levene 检验 (p 值)	0.603 (通过)
MAE	1.666
RMSE	2.316
MAPE	21.143%
R^2	0.862
MAE _{vs 1}	0.714

4.1 尝试方法一：PCA 工作量 + 时序组合预测

方法框架：

- Q1：PCA 职能强度法（本科生、研究生、在编教师 → 综合指标 H → 反推编制）；
- Q2：指数平滑法（Holt）或趋势回归（BIC 选优）；
- 组合：滚动窗口验证 + 方差倒数法定权（独立权重或统一权重）。

四策略版本：

Q2 时序 \ 定权策略	独立权重	统一权重
指数平滑法（Holt）	版本 A	版本 D
趋势回归（BIC 选优）	版本 B	版本 C

4.2 尝试方法二：H、h + 趋势回归预测比例

核心思想：将编制预测转化为比例分配问题，用 PCA 的 H 和 h 框架结合趋势回归预测各学院占比。

实现步骤：

- ① Q1（比例预测）：用 2025 年数据训练 PCA，计算综合职能强度 H_i ，预测比例为

$$r_i^{Q1} = \frac{H_i}{\sum_{j=1}^n H_j}$$

- ② Q2（趋势回归）：对各学院 2022–2026 年的历史编制比例做趋势回归（年份一次项 + 二次项，BIC 选模），外推 2030 年比例 r_i^{Q2} ；
- ③ 组合定权：以 2025→2026 的验证误差确定统一权重 w^{Q1}, w^{Q2} ，组合得

$$r_i = w^{Q1} r_i^{Q1} + w^{Q2} r_i^{Q2}$$

- ④ 总量分配：以 2026 年总编制为基准， $B_i = r_i \cdot B_{\text{total}}$ ，再施加预算约束（含组织员）。

4.3 尝试方法三：比例稳定法 + 逐步回归

核心思想：若学院编制比例稳定，则保持 2026 年比例；不稳定学院用逐步回归预测比例。

实现步骤：

- ① 计算 2022–2026 年各学院编制占比，判断稳定性（变异系数 $CV < 0.15$ 且最大变化 < 0.015 ）；
- ② 稳定学院：直接沿用 2026 年比例；
- ③ 不稳定学院：以 5 维特征训练逐步回归预测比例；
- ④ 优化调整：在总编制守恒 + 预算约束（含组织员）下求解二次规划。

4.4 尝试方法四：PCA 硬约束优化模型

模型设定：

$$\begin{aligned} \min_{y_i} \quad & \sum_{i=1}^n \left(\frac{H_i/y_i - h_i^*}{h_i^*} \right)^2 \\ \text{s.t.} \quad & \sum_{i=1}^n y_i = B_{\text{total}}, \quad 0 < y_i \leq B_i^{\text{预算}} \end{aligned}$$