

高校管理岗编制预测：六种高斯过程回归建模策略对比

全局 GPR、分层部分池化与差分建模的系统性评估

2026 年 7 月 1 日

1 背景

高斯过程回归（GPR）作为一种非参数贝叶斯方法，通过核函数刻画输入特征与输出变量之间的相关结构，不仅能够提供点预测，还能自然地给出预测不确定性区间，是一种在稀疏数据场景下具有优异表现的预测工具。

然而，标准的全局 GPR 假设所有学院共享同一核超参数，忽略了理、工、医、文等不同大类间或者不同学院规模间的结构性差异。为此，构建分层模型并引入部分池化（Partial Pooling）机制，通过收缩权重在“完全独立”与“完全共享”之间寻求最优权衡；进一步采用 K-Means 聚类替代固定行政大类，以数据驱动方式识别同规模学院群体；同时，通过差分建模将预测目标从绝对编制人数转换为年度变动量，弱化历史基数干扰。

总体上，构建了六种建模策略，涵盖原始截面建模与差分建模两大范式，并在每种范式下分别考察全局估计、大类部分池化与聚类部分池化三种结构。所有策略均基于相同的特征组合空间进行超参数优化，以确保结果的可比性。

2 方法原理

2.1 高斯过程回归（GPR）

高斯过程回归假设编制人数的潜在函数 $f(\mathbf{x})$ 服从一个高斯过程：

$$f(\mathbf{x}) \sim \mathcal{GP}(m(\mathbf{x}), k(\mathbf{x}, \mathbf{x}')), \quad (1)$$

其中 $m(\mathbf{x}) = \mathbb{E}[f(\mathbf{x})]$ 为均值函数，通常直接取零均值； $k(\mathbf{x}, \mathbf{x}')$ 为协方差函数（核函数）。本文采用 RBF 核与白噪声核的复合形式：

$$k(\mathbf{x}, \mathbf{x}') = \sigma^2 \exp\left(-\frac{\|\mathbf{x} - \mathbf{x}'\|^2}{2\ell^2}\right) + \sigma_n^2 \delta(\mathbf{x}, \mathbf{x}'), \quad (2)$$

其中 σ^2 为信号方差, ℓ 为长度尺度, σ_n^2 为噪声方差, $\delta(\cdot, \cdot)$ 为 Kronecker delta 函数。

给定训练数据 $\{\mathbf{X}, \mathbf{y}\}$, 对待预测点 $\mathbf{x}^*$, 其函数值 y^* 与训练输出 $\mathbf{y}$ 服从联合高斯分布:

$$\begin{bmatrix} \mathbf{y} \\ y^* \end{bmatrix} \sim \mathcal{N}\left(\mathbf{0}, \begin{bmatrix} \mathbf{K} + \sigma_n^2 \mathbf{I}_n & \mathbf{k}_* \\ \mathbf{k}_*^\top & k_{**} \end{bmatrix}\right), \quad (3)$$

其中 $\mathbf{K}_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$, $\mathbf{k}_* = [k(\mathbf{x}_1, \mathbf{x}^*), \dots, k(\mathbf{x}_n, \mathbf{x}^*)]^\top$, $k_{**} = k(\mathbf{x}^*, \mathbf{x}^*)$ 。

由此可得预测均值与预测方差:

$$\bar{y}^* = \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I}_n)^{-1} \mathbf{y}, \quad (4)$$

$$\text{var}(y^*) = k_{**} - \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I}_n)^{-1} \mathbf{k}_*. \quad (5)$$

超参数 $\boldsymbol{\theta} = (\sigma^2, \ell, \sigma_n^2)$ 通过最大化对数边际似然确定:

$$\log p(\mathbf{y} | \mathbf{X}) = -\frac{1}{2} \mathbf{y}^\top (\mathbf{K} + \sigma_n^2 \mathbf{I}_n)^{-1} \mathbf{y} - \frac{1}{2} \log |\mathbf{K} + \sigma_n^2 \mathbf{I}_n| - \frac{n}{2} \log 2\pi. \quad (6)$$

优化器采用 L-BFGS-B, 并配合 50 次随机重启以避免局部最优。

2.2 部分池化 (Partial Pooling)

部分池化的核心思想在于: 不同分组既不完全共享同一 GPR 模型, 也不完全独立训练, 而是通过收缩权重 λ_k 将全局估计与组内估计进行加权融合。设第 k 组样本量为 n_k , 总组数为 K , 则收缩权重定义为:

$$\lambda_k = \frac{n_k}{n_k + \bar{n}}, \quad \bar{n} = \frac{n_{\text{总}}}{K}. \quad (7)$$

样本量越大的组, 其组内估计获得的信任度越高。最终预测值为:

$$\hat{y}_i = \lambda_k \cdot \hat{y}_i^{(\text{组内})} + (1 - \lambda_k) \cdot \hat{y}_i^{(\text{全局})}. \quad (8)$$

该机制有效避免了小样本组 (如医类、文类部分学院) 的过拟合风险, 同时保留了大样本组的个性化特征。

2.3 K-Means 聚类与部分池化

行政大类 (理/工/医/文) 未必反映编制需求的真正相似性。例如, 土木工程学院与建筑与城市规划学院虽同属工科, 但学生规模与教师结构差异显著。为此, 本文在标准化后的特征空间 $\mathbf{X}_{\text{scaled}}$ 上运行 K-Means 算法 ($K = 3$), 得到聚类标签 $c_i \in \{0, 1, 2\}$, 替代原始大类标签; 进而对每个聚类簇分别训练 GPR, 再按部分池化公式收缩至全局估计。

相较于固定大类, K-Means 聚类以数据驱动方式识别“同规模/同结构”学院群体, 且聚类结果可随特征组合变化而自适应调整, 灵活性更高。

2.4 差分建模 (Differential GPR)

差分建模的基本框架为：

$$\hat{y}_t = y_{t-1} + \widehat{\Delta y}, \quad \text{其中 } \Delta y = \text{GPR}(\Delta X), \Delta X = X_t - X_{t-1}. \quad (9)$$

引入差分建模的动机在于：第一，消除基数异质性——不同学院编制基数差异巨大（0-27 人），直接预测绝对量导致大学院主导损失函数；第二，聚焦边际变动——政策调整通常关注“增多少、减多少”，差分直接建模变动量；第三，弱化历史年份影响——2024 年数据仅用于提供基准 y_{t-1} ，模型核心学习 2025 至 2026 年的变动规律；第四，兼容缺失特征——2024 年缺失留学生人数等列，差分版本通过排除这些列，仅使用在编教辅/思政/管理/工勤、博士后、派遣、高研院、柔性等可用扩展特征。

3 六种建模策略与实证结果

本文共构建六种策略，涵盖原始方法（A-C）与差分方法（D-F）。原始方法基于 2026 年截面数据自预测，特征组合空间包含“本 + 研 + 师”及其留学生扩展、公共课选项与 7 组扩展特征开关，共 1,152 种组合；差分方法基于 2025 至 2026 年差分训练，排除 2024 缺失列后保留 5 组扩展开关，共 96 种组合。所有策略均以 MAE_vs 官方参数 1 为主要排序指标，辅以 R^2 与 MAE_vs 实际。

3.1 方法 A：全局 GPR（原始）

方法 A 对所有学院共享同一核超参数，不考虑分组结构。最优特征组合为“本 + 研 + 师”。

精度指标方面，MAE_vs 实际为 1.644，RMSE_vs 实际为 2.321，MAE_vs 参数 1 为 0.707，RMSE_vs 参数 1 为 1.096， $R^2 = 0.861$ 。统计检验均通过：配对 t 检验 $p = 0.953$ ，F 检验 $p = 0.534$ ，Levene 检验 $p = 0.567$ 。

超参数估计结果为：信号方差 $\sigma^2 = 1.6687$ ，长度尺度 $\ell = 3.4546$ ，噪声方差 $\sigma_n^2 = 0.1000$ 。较大的长度尺度表明模型在特征空间中采用了较平滑的插值策略。

3.2 方法 B：大类部分池化 GPR（原始）

方法 B 在方法 A 基础上引入按理/工/医/文分组的部分池化。最优特征组合仍为“本 + 研 + 师”。

精度指标显示，MAE_vs 实际降至 0.895，RMSE_vs 实际降至 1.292， R^2 提升至 0.957；然而 MAE_vs 参数 1 升至 1.165，RMSE_vs 参数 1 升至 1.507。这表明部分池化显著改善了实际编制拟合，但预测值系统性偏离了仅含学生数与教师数的 OLS 拟合面。

超参数与收缩权重方面，全局超参数为 $\sigma^2 = 1.6687$, $\ell = 3.4546$, $\sigma_n^2 = 0.1000$ 。各组估计显示：理类收缩权重 $\lambda = 0.339$ ，组内超参数 $(0.9900, 0.0100, 7.9 \times 10^{-5})$ ；工类 $\lambda = 0.621$ ，组内超参数 $(1.1924, 1.2367, 1.0 \times 10^{-5})$ ；医类 $\lambda = 0.170$ ，组内超参数 $(0.9900, 0.0818, 5.0 \times 10^{-6})$ ；文类 $\lambda = 0.621$ ，组内超参数 $(0.9364, 0.0100, 0.1000)$ 。工类与文类较高的收缩权重反映了其较大的样本量与组内估计的可信度。

3.3 方法 C：聚类部分池化 GPR（原始）

方法 C 采用 K-Means ($K = 3$) 替代固定大类进行聚类与部分池化。最优特征组合为”本 + 研 + 师 + 是否公课 + 一年制”。

精度指标为：MAE_vs 实际 0.926，RMSE_vs 实际 1.253，MAE_vs 参数 11.087，RMSE_vs 参数 11.427， $R^2 = 0.960$ 。统计检验均通过： p 值分别为 0.924、0.623 与 0.607。

聚类结构与超参数显示：全局超参数为 $(1.9662, 4.6928, 0.1000)$ ；组 0（19 个学院，中小规模） $\lambda = 0.594$ ，超参数 $(0.9289, 0.0100, 0.1000)$ ；组 1（12 个学院，中等规模） $\lambda = 0.480$ ，超参数 $(1.3917, 0.4981, 0.0000)$ ；组 2（8 个学院，大规模） $\lambda = 0.381$ ，超参数 $(0.9900, 0.0100, 4.5 \times 10^{-5})$ 。组 0 包含海洋与地球科学学院、生命科学与技术学院、设计创意学院等；组 1 包含物理、数学、化学、机械、计算机、人文、外国语等；组 2 包含汽车、电子、环境、土木、交通、建筑、医学、经管等。

3.4 方法 D：差分全局 GPR

方法 D 转向差分建模，预测 2025 至 2026 年的编制变动量。最优特征组合为”本 + 研 + 师 + 在编 + 博士后 + 高研院”。

精度指标显著改善：MAE_vs 实际 0.252，RMSE_vs 实际 0.446， $R^2 = 0.995$ ；MAE_vs 参数 11.725，RMSE_vs 参数 12.267。统计检验均通过： p 值分别为 0.813、0.999 与 0.983。

超参数估计为 $\sigma^2 = 1.4905$ ， $\ell = 0.9197$ ， $\sigma_n^2 = 0.1000$ 。相较于方法 A，长度尺度显著减小，表明差分后特征空间的局部结构更为复杂，模型需要更敏感的插值。

3.5 方法 E：差分大类部分池化 GPR

方法 E 在差分框架下引入大类部分池化，为本文精度最优策略。最优特征组合为”本 + 研 + 师 + 派遣 + 高研院”。

精度指标达到：MAE_vs 实际 **0.088**，RMSE_vs 实际 **0.192**， $R^2 = \mathbf{0.999}$ ；MAE_vs 参数 11.749，RMSE_vs 参数 12.258。统计检验均通过： p 值分别为 0.956、0.993 与 0.987。

超参数与收缩权重显示：全局超参数 $(0.8102, 0.1127, 0.1000)$ ；理类 $\lambda = 0.351$ ，组内 $(0.9900, 0.0100, 5.0 \times 10^{-6})$ ；工类 $\lambda = 0.634$ ，组内 $(0.9650, 0.0383, 0.0084)$ ；医类 $\lambda = 0.178$ ，组内 $(0.9900, 0.0818, 5.0 \times 10^{-6})$ ；文类 $\lambda = 0.602$ ，组内 $(0.9900, 0.0100, 1.0 \times 10^{-5})$ 。差分框架下各组长度尺度均显著小于原始方法，反映了变动量空间的高度非线性。

3.6 方法 F：差分聚类部分池化 GPR

方法 F 在差分框架下采用 K-Means 聚类部分池化。最优特征组合为”本 + 研 + 师 + 在编 + 高研院”。

精度指标为：MAE_vs 实际 0.256, RMSE_vs 实际 0.452, $R^2 = 0.995$; MAE_vs 参数 11.722, RMSE_vs 参数 12.268。统计检验均通过：p 值分别为 0.820、0.998 与 0.981。

聚类结构与超参数显示：全局超参数 (1.4234, 0.8634, 0.1000)；组 0 (36 个学院，绝大多数) $\lambda = 0.735$ ，超参数 (1.8167, 1.0645, 0.1000)；组 1 (2 个超大规模工科：环境科学与工程、土木工程) $\lambda = 0.133$ ，超参数 (0.9900, 0.0818, 5.0×10^{-6})；组 2 (1 个学院：汽车与能源学院) $\lambda = 0.000$ ，完全收缩至全局。组 2 样本量不足导致其组内估计不可信，权重归零，体现了部分池化机制的自适应稳健性。

4 综合对比与讨论

表1汇总了六种方法的核心精度指标。

表 1: 六种方法精度对比总表

方法	MAE_vs 实际	RMSE_vs 实际	MAE_vs 参数 1	R^2
A 全局 GPR (原始)	1.644	2.321	0.707	0.861
B 大类部分池化 (原始)	0.895	1.292	1.165	0.957
C 聚类部分池化 (原始)	0.926	1.253	1.087	0.960
D 差分全局 GPR	0.252	0.446	1.725	0.995
E 差分大类部分池化	0.088	0.192	1.749	0.999
F 差分聚类部分池化	0.256	0.452	1.722	0.995

从拟合实际编制的角度，差分大类部分池化（方法 E）以 MAE_vs 实际 =0.088、 $R^2 = 0.999$ 显著优于其余策略。然而，所有差分方法的 MAE_vs 参数 1 均处于 1.7–1.8 区间，明显高于原始方法 A 的 0.707。这一现象的根源在于信息集差异：官方参数 1 仅基于学生数与教师数的线性 OLS 估计，而 GPR 额外纳入了在编教辅、博士后、派遣、高研院等扩展特征。这些扩展特征对 2026 年实际编制具有显著解释力，故 GPR 预测更贴近实际编制，却自然偏离了仅含两变量的 OLS 拟合面。

聚类/分类与差分的结合具有多重价值：第一，充分利用新扩展特征向量，差分后变动信号更为清晰；第二，部分池化通过收缩权重平衡组内个性化与全局稳定性，通常可降低 MAE_vs 实际 45% 以上；第三，固定大类尊重行政归属与学科生态，K-Means 聚类则以数据驱动识别同规模学院群体，避免大类内部异质性导致的估计偏误；第四，差分建模将 2024 年数据仅作为基准 y_{t-1} 加回，显著削弱了历史异常值对核超参数的影响。

关于预测值向官方参数 1 收缩的改进路径, 建议采用残差 GPR (Residual GPR) 框架: 将官方 OLS 参数 1 作为固定效应先验, GPR 负责拟合 OLS 未能解释的残差结构。。