

高校管理岗编制预测：六种高斯过程回归建模策略对比

全局 GPR、分层部分池化与差分建模的系统性评估

2026 年 7 月 1 日

1.1 六种建模策略总览

核心目标：预测 2026 年各学院管理岗编制人数（含组织员），并划分为正科、副科、科级以下。

六种策略：

编号	策略名称	训练模式	组合数
A	全局 GPR（原始）	所有学院做 GPR	1,152
B	大类部分池化 GPR	理/工/医/文分组做 GPR + 收缩	1,152
C	聚类部分池化 GPR	K-Means 聚类做 GPR+ 收缩	1,152
D	差分全局 GPR	全局差分做 GPR	96
E	差分大类部分池化 GPR	差分 + 按大类分组收缩	96
F	差分聚类部分池化 GPR	差分 + K-Means 聚类收缩	96

特征组合：原始方法含“本 + 研 + 师”及其留学生扩展 × 公共课选项 × 7 组扩展特征开关；差分方法排除 2024 缺失列后保留 5 组扩展开关。

2.1 高斯过程

基本假设： 编制人数潜在函数 $f(\mathbf{x})$ 服从一个高斯过程：

$$f(\mathbf{x}) \sim \mathcal{GP}(m(\mathbf{x}), k(\mathbf{x}, \mathbf{x}'))$$

均值函数（一般直接取零均值）：

$$m(\mathbf{x}) = \mathbb{E}[f(\mathbf{x})]$$

协方差函数（核函数）： 采用 RBF + 白噪声核

$$k(\mathbf{x}, \mathbf{x}') = \sigma^2 \exp\left(-\frac{\|\mathbf{x} - \mathbf{x}'\|^2}{2\ell^2}\right) + \sigma_n^2 \delta(\mathbf{x}, \mathbf{x}')$$

关键点

GPR 可通过不同超参数确定不同形态高斯过程，保证输出一定符合高斯过程。

2.1 最大化边际似然确定超参数

边际似然：给定数据与超参数时观察到函数值的概率

$$p(\mathbf{y} \mid \mathbf{X}) = \int p(\mathbf{y} \mid \mathbf{f}) p(\mathbf{f} \mid \mathbf{X}) d\mathbf{f} = \mathcal{N}(\mathbf{0}, \mathbf{K} + \sigma_n^2 \mathbf{I}_n)$$

对数边际似然：

$$\log p(\mathbf{y} \mid \mathbf{X}) = -\frac{1}{2} \mathbf{y}^\top (\mathbf{K} + \sigma_n^2 \mathbf{I}_n)^{-1} \mathbf{y} - \frac{1}{2} \log |\mathbf{K} + \sigma_n^2 \mathbf{I}_n| - \frac{n}{2} \log 2\pi$$

超参数优化：通过最大化 $\log p(\mathbf{y} \mid \mathbf{X})$ 确定 $\theta = (\sigma^2, \ell, \sigma_n^2)$ ，优化器采用 L-BFGS-B，配合 50 次随机重启保证找到全局最优解。

2.1 预测函数的推导

联合分布：由于待预测点函数值也符合高斯过程，可对训练输出 y 与待预测点 x^* 的函数值 y^* ，构造联合高斯分布

$$\begin{bmatrix} y \\ y^* \end{bmatrix} \sim \mathcal{N}\left(\mathbf{0}, \begin{bmatrix} \mathbf{K} + \sigma_n^2 \mathbf{I}_n & \mathbf{k}_* \\ \mathbf{k}_*^\top & k_{**} \end{bmatrix}\right)$$

其中 $K_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$, $\mathbf{k}_* = [k(\mathbf{x}_1, \mathbf{x}^*), \dots, k(\mathbf{x}_n, \mathbf{x}^*)]^\top$, $k_{**} = k(\mathbf{x}^*, \mathbf{x}^*)$ 。

预测均值（即预测输出值）：

$$\bar{y}^* = \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I}_n)^{-1} \mathbf{y}$$

预测方差（用以确定预测区间）：

$$\text{var}(y^*) = k_{**} - \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I}_n)^{-1} \mathbf{k}_*$$

2.2 部分池化 (Partial Pooling)

核心思想：不同分组既不完全共享同一 GPR 模型，也不完全独立训练，而是通过**收缩权重** λ 将全局估计与组内估计进行加权融合。

收缩权重公式：

$$\lambda_k = \frac{n_k}{n_k + \bar{n}}, \quad \bar{n} = \frac{n_{\text{总}}}{K}$$

其中 n_k 为第 k 组样本量， K 为组数。样本量越大的组，越信任其组内估计。

最终预测：

$$\hat{y}_i = \lambda_k \cdot \hat{y}_i^{(\text{组内})} + (1 - \lambda_k) \cdot \hat{y}_i^{(\text{全局})}$$

意义

避免小样本组（如医类、文类部分学院）的过拟合，同时保留大样本组的个性化特征。

2.3 K-Means 聚类

动机：行政大类（理/工/医/文）未必反映编制需求的真正相似性。例如，“土木工程学院”与“建筑与城市规划学院”虽同属工科，但学生规模、教师结构差异显著。

实现步骤：

- ① 在标准化后的特征空间 $\mathbf{X}_{\text{scaled}}$ 上运行 K-Means ($K = 3$)；
- ② 得到聚类标签 $c_i \in \{0, 1, 2\}$ ，替代原始大类标签；
- ③ 对每个聚类簇分别训练 GPR，再按部分池化公式收缩至全局估计。

优势：

- 以数据驱动方式识别“同规模/同结构”学院群体；
- 聚类结果可随特征组合变化而自适应调整，灵活性高于固定大类。

2.4 差分建模 (Differential GPR)

基本框架：

$$\hat{y}_t = y_{t-1} + \widehat{\Delta y}, \quad \text{其中 } \Delta y = \text{GPR}(\Delta X), \Delta X = X_t - X_{t-1}$$

为什么做差分？

- 消除基数异质性：不同学院编制基数差异巨大，直接预测绝对量导致大学院主导函数；
- 聚焦边际变动：政策调整通常关注“增多少、减多少”，差分直接建模变动量；
- 弱化历史年份影响：聚焦于 25 到 26 的变动值，弱化了历史年份的影响；。

3.1 方法 A：全局 GPR（原始）

最优特征组合：本 + 研 + 师

精度指标

指标	数值
MAE_vs 实际	1.644
RMSE_vs 实际	2.321
MAE_vs 参数 1	0.707
RMSE_vs 参数 1	1.096
R^2	0.861

超参数与统计检验

项目	结果
信号方差 σ^2	1.6687
长度尺度 ℓ	3.4546
噪声方差 σ_n^2	0.1000
t 检验 (p 值)	0.953 (通过)
F 检验 (p 值)	0.534 (通过)
Levene (p 值)	0.567 (通过)

3.2 方法 B：大类部分池化 GPR（原始）

最优特征组合：本 + 研 + 师

精度指标

指标	数值
MAE_vs 实际	0.895
RMSE_vs 实际	1.292
MAE_vs 参数 1	1.165
RMSE_vs 参数 1	1.507
R^2	0.957

超参数、收缩权重与统计检验

分组	σ^2	ℓ	σ_n^2
全局	1.6687	3.4546	0.1000
理 ($\lambda=0.339$)	0.9900	0.0100	7.9×10^{-5}
工 ($\lambda=0.621$)	1.1924	1.2367	1.0×10^{-5}
医 ($\lambda=0.170$)	0.9900	0.0818	5.0×10^{-6}
文 ($\lambda=0.621$)	0.9364	0.0100	0.1000

检验	结果
t 检验 (p 值)	0.698 (通过)
F 检验 (p 值)	0.606 (通过)
Levene (p 值)	0.607 (通过)

3.3 方法 C：聚类部分池化 GPR（原始）

最优特征组合：本 + 研 + 师 + 是否公课 + 一年制

超参数、收缩权重与统计检验

精度指标

指标	数值
MAE_vs 实际	0.926
RMSE_vs 实际	1.253
MAE_vs 参数 1	1.087
RMSE_vs 参数 1	1.427
R^2	0.960

分组	σ^2	ℓ	σ_n^2
全局	1.9662	4.6928	0.1000
组 0 ($\lambda=0.594$)	0.9289	0.0100	0.1000
组 1 ($\lambda=0.480$)	1.3917	0.4981	0.0000
组 2 ($\lambda=0.381$)	0.9900	0.0100	4.5×10^{-5}

检验	结果
t 检验 (p 值)	0.924 (通过)
F 检验 (p 值)	0.623 (通过)
Levene (p 值)	0.607 (通过)

3.4 方法 D：差分全局 GPR

最优特征组合：本 + 研 + 师 + 在编 + 博士后 + 高研院

精度指标

超参数与统计检验

指标	数值
MAE_vs 实际	0.252
RMSE_vs 实际	0.446
MAE_vs 参数 1	1.725
RMSE_vs 参数 1	2.267
R^2	0.995

项目	结果
信号方差 σ^2	1.4905
长度尺度 ℓ	0.9197
噪声方差 σ_n^2	0.1000
t 检验 (p 值)	0.813 (通过)
F 检验 (p 值)	0.999 (通过)
Levene (p 值)	0.983 (通过)

3.5 方法 E：差分大类部分池化 GPR

最优特征组合：本 + 研 + 师 + 派遣 + 高研院

精度指标

指标	数值
MAE_vs 实际	0.088
RMSE_vs 实际	0.192
MAE_vs 参数 1	1.749
RMSE_vs 参数 1	2.258
R^2	0.999

超参数、收缩权重与统计检验

分组	σ^2	ℓ	σ_n^2
全局	0.8102	0.1127	0.1000
理 ($\lambda=0.351$)	0.9900	0.0100	5.0×10^{-6}
工 ($\lambda=0.634$)	0.9650	0.0383	0.0084
医 ($\lambda=0.178$)	0.9900	0.0818	5.0×10^{-6}
文 ($\lambda=0.602$)	0.9900	0.0100	1.0×10^{-5}

检验	结果
t 检验 (p 值)	0.956 (通过)
F 检验 (p 值)	0.993 (通过)
Levene (p 值)	0.987 (通过)

3.6 方法 F：差分聚类部分池化 GPR

最优特征组合：本 + 研 + 师 + 在编 + 高研院

精度指标

指标	数值
MAE_vs 实际	0.256
RMSE_vs 实际	0.452
MAE_vs 参数 1	1.722
RMSE_vs 参数 1	2.268
R^2	0.995

超参数、收缩权重与统计检验

分组	σ^2	ℓ	σ_n^2
全局	1.4234	0.8634	0.1000
组 0 ($\lambda=0.735$)	1.8167	1.0645	0.1000
组 1 ($\lambda=0.133$)	0.9900	0.0818	5.0×10^{-6}
组 2 ($\lambda=0.000$)	1.4234	0.8634	0.1000

检验	结果
t 检验 (p 值)	0.820 (通过)
F 检验 (p 值)	0.998 (通过)
Levene (p 值)	0.981 (通过)

4.1 六种方法汇总表

方法	MAE_vs 实际	RMSE_vs 实际	MAE_vs 参数 1	R^2	通过检验
A 全局 GPR (原始)	1.644	2.321	0.707	0.861	是
B 大类部分池化 (原始)	0.895	1.292	1.165	0.957	是
C 聚类部分池化 (原始)	0.926	1.253	1.087	0.960	是
D 差分全局 GPR	0.252	0.446	1.725	0.995	是
E 差分大类部分池化	0.088	0.192	1.749	0.999	是
F 差分聚类部分池化	0.256	0.452	1.722	0.995	是

排序依据：以 MAE_vs 官方参数 1 为主要排序指标，辅以 R^2 与 MAE_vs 实际。从拟合实际编制的角度看，方法 E（差分大类部分池化）以 MAE_vs 实际 = 0.088、 $R^2 = 0.999$ 显著优于其余策略。

4.2 聚类/分类 + 差分更有价值

- ① 充分利用新扩展特征向量
- ② 对实际数据的拟合精度更优
- ③ 考虑不同大类/不同规模学院之间的差异
- ④ 差分减少前年份数据的影响

4.3 后续发展

- **若向贴近官方参数 1：**调整 GPR 的均值函数，将零均值函数替换为官方拟合函数，此时 GPR 不再解释编制人数值的变动，而是解释官方 OLS 未能解释的残差结构，应会天然向官方参数 1 收缩；
- **方法改进：**仍需阅读更多相关文献，学习预测方法。