

1 1.1 研究背景与目标

首先介绍研究背景与目标。研究目标是预测 2030 年各学院管理岗编制，并按正科、副科、科级以下三个层级拆分。

我们选取了五个特征变量：本科生、研究生、在编教师、留学生、公共课学分。这些指标能综合反映学院的管理工作量。验证策略上，采用“训练—验证—预测”三步走：用 2025 年数据训练模型，2026 年实际数据验证模型精度，通过统计检验后再外推至 2030 年。这种滚动验证能最大程度保证外推的可信度。

验证策略：

$$\text{训练集 (2025 年)} \xrightarrow{\text{GPR 拟合}} \text{验证集 (2026 年)} \xrightarrow{\text{假设检验}} \text{2030 年预测} \quad (1)$$

2 1.2 符号说明

设有 n 个学院， $i = 1, \dots, n$ 为学院编号， $n = 27$ （排除 2 个特殊学院）。定义以下符号：

表 1: 符号定义

符号	含义
$\mathbf{x}_i$	第 i 个学院的特征向量（5 维）
$B_{i,t}$	第 i 个学院第 t 年的实际编制人数
$\hat{B}_{i,t}$	GPR 预测编制人数
$f(\mathbf{x})$	潜在编制人数函数，服从高斯过程
$\mu(\mathbf{x}^*)$	GPR 预测均值函数
$\sigma^2(\mathbf{x}^*)$	GPR 预测方差（不确定性）
$B_i^{\text{预算}}$	预算约束人数（总编制上限）
$\alpha_1, \alpha_2, \alpha_3$	正科、副科、科级以下拆分比例（0.2, 0.3, 0.5）

注意：我们排除了上海国际知识产权学院和中德工程学院，因为这两个学院数据特殊，容易干扰模型。最终编制按 2 : 3 : 5 拆分为正科、副科、科级以下，这是学校人事处的统一规定。

3 2.1 高斯过程

进入方法部分。高斯过程回归的核心思想是：我们不直接假设编制人数与特征之间的具体函数形式（比如线性或二次），而是假设这个函数本身服从一个高斯过程。

基本假设：编制人数潜在函数 $f(\mathbf{x})$ 服从一个高斯过程：

$$f(\mathbf{x}) \sim \mathcal{GP}(m(\mathbf{x}), k(\mathbf{x}, \mathbf{x}')) \quad (2)$$

均值函数（此处取零均值或数据均值）：

$$m(\mathbf{x}) = \mathbb{E}[f(\mathbf{x})] \quad (3)$$

协方差函数（核函数）：采用 RBF + 白噪声核

$$k(\mathbf{x}, \mathbf{x}') = \sigma^2 \exp\left(-\frac{\|\mathbf{x} - \mathbf{x}'\|^2}{2\ell^2}\right) + \sigma_n^2 \delta(\mathbf{x}, \mathbf{x}') \quad (4)$$

RBF 核的直观含义是：两个学院特征越接近，它们的编制人数应该越相似；白噪声项则捕捉观测误差。GPR 的一大优势是天然提供预测区间 $\mu(\mathbf{x}^*) \pm 1.96\sigma(\mathbf{x}^*)$ ，这对编制规划很重要——我们不仅要知道预测值，还要知道不确定性。

4 2.2 最大化边际似然确定超参数

边际似然：给的数据与超参数时观察到函数值的概率。对潜在函数 f 积分消去后，观测数据服从多元高斯分布：

$$p(\mathbf{y} | \mathbf{X}) = \int p(\mathbf{y} | \mathbf{f}) p(\mathbf{f} | \mathbf{X}) d\mathbf{f} = \mathcal{N}(\mathbf{0}, \mathbf{K} + \sigma_n^2 \mathbf{I}_n) \quad (5)$$

具体函数形式：

$$p(\mathbf{y} | \mathbf{X}) = (2\pi)^{-n/2} |\mathbf{K} + \sigma_n^2 \mathbf{I}_n|^{-1/2} \exp\left\{-\frac{1}{2} \mathbf{y}^\top (\mathbf{K} + \sigma_n^2 \mathbf{I}_n)^{-1} \mathbf{y}\right\} \quad (6)$$

对数边际似然：

$$\log p(\mathbf{y} | \mathbf{X}) = -\frac{1}{2} \mathbf{y}^\top (\mathbf{K} + \sigma_n^2 \mathbf{I}_n)^{-1} \mathbf{y} - \frac{1}{2} \log |\mathbf{K} + \sigma_n^2 \mathbf{I}_n| - \frac{n}{2} \log 2\pi \quad (7)$$

超参数优化：通过最大化 $\log p(\mathbf{y} | \mathbf{X})$ 确定 $\boldsymbol{\theta} = (\sigma^2, \ell, \sigma_n^2)$ ，优化器采用 L-BFGS-B，配合 50 次随机重启避免局部最优。

为什么取对数？一是乘积变求和，避免数值下溢；二是求导更稳定，梯度有简洁的解析表达式；三是对数函数严格单调，最优解不变。

5 2.3 预测函数的推导

联合分布：对训练输出 $\mathbf{y}$ 与待预测点 $\mathbf{x}^*$ 的函数值 y^* ，构造联合高斯分布

$$\begin{bmatrix} \mathbf{y} \\ y^* \end{bmatrix} \sim \mathcal{N}\left(\mathbf{0}, \begin{bmatrix} \mathbf{K} + \sigma_n^2 \mathbf{I}_n & \mathbf{k}_* \\ \mathbf{k}_*^\top & k_{**} \end{bmatrix}\right) \quad (8)$$

其中 $\mathbf{K}_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$ ， $\mathbf{k}_* = [k(\mathbf{x}_1, \mathbf{x}^*), \dots, k(\mathbf{x}_n, \mathbf{x}^*)]^\top$ ， $k_{**} = k(\mathbf{x}^*, \mathbf{x}^*)$ 。

由多元高斯条件分布：

$$y^* | \mathbf{X}, \mathbf{y}, \mathbf{x}^* \sim \mathcal{N}(\bar{y}^*, \text{var}(y^*)) \quad (9)$$

预测均值:

$$\bar{y}^* = \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I}_n)^{-1} \mathbf{y} \quad (10)$$

预测方差:

$$\text{var}(y^*) = k_{**} - \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I}_n)^{-1} \mathbf{k}_* \quad (11)$$

预测均值的直观理解: 它是训练观测值 $\mathbf{y}$ 的加权线性组合, 权重由待预测点与训练点的相似度 $\mathbf{k}_*$ 决定。预测方差则反映了不确定性: 当待预测点远离训练数据时, k_{**} 占主导, 方差变大; 当靠近训练数据时, 第二项抵消更多, 方差变小。

6 2.4 代码中的 alpha 噪声参数

在 sklearn 的 GaussianProcessRegressor 中, $\text{alpha}=1\text{e-}2$ 对应的是**附加噪声方差**的数值。代码设置:

$$\mathbf{K}_{\text{有效}} = \mathbf{K} + 10^{-2} \cdot \mathbf{I}_n \quad (12)$$

该参数有两重作用:

1. **数值稳定性**: 防止核矩阵 $\mathbf{K}$ 接近奇异时求逆失败;
2. **正则化**: 控制模型对训练数据的拟合程度, 避免过拟合。

与核函数噪声的关系: 核函数中 WhiteKernel 的 σ_n^2 经优化后为 0.1000, 而 $\text{alpha}=1\text{e-}2$ 提供额外的正则化项。但在汇报理论模型时, 我们只写概率模型认可的 σ_n^2 , 不写工程实现的 alpha , 因为 $\sigma_n^2 = 0.1000$ 已主导噪声水平。

7 2.5 模型拟合结果与最终预测函数

训练后核函数参数:

信号方差 σ^2	长度尺度 ℓ	噪声方差 σ_n^2
1.1576	2.9821	0.1000

最终核函数:

$$k(\mathbf{x}, \mathbf{x}') = 1.1576 \cdot \exp\left(-\frac{\|\mathbf{x} - \mathbf{x}'\|^2}{17.7857}\right) + 0.1000 \cdot \delta(\mathbf{x}, \mathbf{x}') \quad (13)$$

最终预测均值函数:

$$\mu(\mathbf{x}^*) = \mathbf{k}_*^\top (\mathbf{K} + 0.1000 \cdot \mathbf{I}_n)^{-1} \mathbf{y} \quad (14)$$

最终预测方差函数:

$$\sigma^2(\mathbf{x}^*) = 1.1576 - \mathbf{k}_*^\top (\mathbf{K} + 0.1000 \cdot \mathbf{I}_n)^{-1} \mathbf{k}_* \quad (15)$$

其中 $\mathbf{K}_{ij} = 1.1576 \exp(-\|\mathbf{x}_i - \mathbf{x}_j\|^2/17.7857)$, $\mathbf{k}_*$ 为待预测点与训练点的协方差向量。长度尺度约 3, 意味着特征空间中距离约 3 个标准差时, 相关性显著衰减。

8 3.1 验证方法

以 2025 年数据训练、2026 年数据验证, 对 GPR 预测结果进行统计检验:

1. **配对 t 检验**: 检验预测值与实际值的均值差异, $H_0: \mu_{\text{pred}} = \mu_{\text{actual}}$;
2. **F 检验**: 检验预测值与实际值的方差齐性, $H_0: \sigma_{\text{pred}}^2 = \sigma_{\text{actual}}^2$;
3. **Levene 检验**: 方差齐性稳健检验;
4. **精度指标**: MAE、RMSE、MAPE、 R^2 。

四层检验的设计逻辑: 配对 t 检验看均值是否一致, 防止系统性高估或低估; F 检验和 Levene 检验看方差是否一致, 防止预测值过于集中或分散; MAE、RMSE、 R^2 则提供直观的精度度量。只有同时通过均值检验和方差检验, 才能说明模型具有外推可信度。

9 3.2 假设检验与精度指标 (2025→2026 验证集)

表 2: GPR 假设检验与精度指标 (2025→2026 验证集)

检验/指标	统计量	结果
配对 t 检验 (p 值)	$t = -0.1556$	0.8776 (通过)
F 检验 (p 值)	$F = 1.1911$	0.6590 (通过)
Levene 检验 (p 值)	—	0.7377 (通过)
MAE	1.4077	
RMSE	2.3115	
MAPE	16.19%	
R^2	0.7976	

验证结果非常理想。三项假设检验全部通过, p 值分别为 0.8776、0.6590、0.7377, 均远大于 0.05 的显著性水平。这说明 GPR 预测值与 2026 年实际编制在均值和方差上都没有显著差异, 模型没有系统性高估或低估。

R^2 为 0.7976, 意味着模型能解释约 80% 的编制人数变异。考虑到编制人数还受政策、历史沿革等非量化因素影响, 这个精度是可以接受的。基于这些结果, 我们有信心将模型外推至 2030 年。

10 4.1 GPR 预测结果与官方 OLS 拟合对比

这一页展示 2030 年 GPR 预测值与官方 OLS 拟合值的对比图(gpr_reproducible.png)。

从柱状图可以看出，大部分学院的 GPR 预测值与官方 OLS 结果高度吻合，散点图的 R^2 达到 0.898，说明两种方法在整体趋势上高度一致。差异较大的几个点主要是文科学院，这些学院的特征变量波动较大，但总体偏差仍在可接受范围内。

这张图说明 GPR 不仅能给出合理的点预测，还能提供置信区间，这是 OLS 线性回归所不具备的优势。官方 OLS 只能给出点估计，而 GPR 能提供 $\mu \pm 1.96\sigma$ 的预测区间，为编制规划的风险评估提供量化依据。

11 4.2 预算约束优化模型

对第 i 个学院，设 GPR 预测总编制为 $\hat{B}_i$ ，预算上限为 $B_i^{\text{预算}}$ 。

原始规划：

$$\begin{aligned} \min_{\hat{y}_{i,1}, \hat{y}_{i,2}, \hat{y}_{i,3}} \quad & \sum_{j=1}^3 (\hat{y}_{i,j} - y_{i,j})^2 \\ \text{s.t.} \quad & \sum_{j=1}^3 \hat{y}_{i,j} \leq B_i^{\text{预算}} \end{aligned} \tag{16}$$

解析解：

- 若 $\hat{B}_i \leq B_i^{\text{预算}}$ ：保持原预测，按 2:3:5 拆分；
- 若 $\hat{B}_i > B_i^{\text{预算}}$ ：压缩至预算上限，再按 2:3:5 拆分。

经济学含义：三类编制同步等额缩减，最大限度贴近原 2:3:5 配比，避免某一级级被过度压缩。这避免了“只砍科级以上”或“只砍正科”的极端调整，保持了管理层级的结构稳定性。

12 4.3 预算约束后的层级拆分

2030 年预测总编制：

- 约束前：258.13 人
- 约束后：253.31 人
- 预算约束合计：334 人

超预算学院 (7 个)：测绘与地理信息学院、航空航天与力学学院、人文学院、政治与国际关系学院、马克思主义学院、国际文化交流学院、法学院。

上述 7 个学院的 GPR 预测值与官方 OLS 拟合结果基本一致；由于预测值超出预算上限，约束后均按**预算上限**取值，再按 2:3:5 拆分为正科、副科、科级以下。

结构比例：正科约占 20.0%，副科约占 30.0%，科级以下约占 50.0%，符合 2:3:5 的预设配比。

13 5.1 尝试方法一：PCA 工作量 + 时序组合预测

方法框架：

- **Q1**：PCA 职能强度法（本科生、研究生、在编教师 → 综合指标 H → 反推编制）；
- **Q2**：指数平滑法（Holt）或趋势回归（BIC 选优）；
- **组合**：滚动窗口验证 + 方差倒数法定权（独立权重或统一权重）。

四策略版本：

Q2 时序 \ 定权策略	独立权重	统一权重
指数平滑法（Holt）	版本 A	版本 D
趋势回归（BIC 选优）	版本 B	版本 C

14 5.2 尝试方法二：H、h + 趋势回归预测比例

核心思想：将编制预测转化为**比例分配**问题，用 PCA 的 H 和 h 框架结合趋势回归预测各学院占比。

实现步骤：

1. **Q1（比例预测）**：用 2025 年数据训练 PCA，计算综合职能强度 H_i ，预测比例为

$$r_i^{Q1} = \frac{H_i}{\sum_{j=1}^n H_j} \quad (17)$$

2. **Q2（趋势回归）**：对各学院 2022–2026 年历史编制比例做趋势回归（年份一次项 + 二次项，BIC 选模），外推 2030 年比例 r_i^{Q2} ；

3. **组合定权**：以 2025→2026 的验证误差确定统一权重 w^{Q1}, w^{Q2} ，组合得

$$r_i = w^{Q1} r_i^{Q1} + w^{Q2} r_i^{Q2} \quad (18)$$

4. **总量分配**：以 2026 年总编制为基准， $B_i = r_i \cdot B_{\text{total}}$ ，再施加预算约束。

15 5.3 尝试方法三：比例稳定法 + 逐步回归

核心思想：若学院编制比例稳定，则保持 2026 年比例；不稳定学院用逐步回归预测比例。

实现步骤：

1. 计算 2022–2026 年各学院编制占比，判断稳定性（变异系数 $CV < 0.15$ 且最大变化 < 0.015 ）；
2. 稳定学院：直接沿用 2026 年比例；
3. 不稳定学院：以 5 维特征训练逐步回归预测比例；
4. 优化调整：在总编制守恒 + 预算约束下求解二次规划。

16 5.4 尝试方法四：PCA 硬约束优化模型

模型设定：

$$\begin{aligned} \min_{y_i} \quad & \sum_{i=1}^n \left(\frac{H_i/y_i - h_i^*}{h_i^*} \right)^2 \\ \text{s.t.} \quad & \sum_{i=1}^n y_i = B_{\text{total}}, \quad 0 < y_i \leq B_i^{\text{预算}} \end{aligned} \tag{19}$$